

UNIVERSIDAD MAYOR DE SAN SIMÓN

PROYECTO DE GRADO

Detección de anomalías de conducción

Autor:
Evelyn CUSI LÓPEZ

Tutor:
Dr. Eduardo DI SANTI

*Un proyecto de grado presentado en cumplimiento de los requisitos
para el título de Licenciatura en Ingeniería de Sistemas*

en la

Carrera de Ingeniería de Sistemas
Departamento Informática-Sistemas

7 de enero de 2019

Agradecimientos

Le agradezco a Dios por haberme acompañado y guiado a lo largo de mi carrera, por ser mi fortaleza en los momentos de debilidad y por brindarme una vida llena de aprendizajes, experiencias y sobre todo felicidad.

A mi madre, por estar conmigo, por enseñarme a crecer y a levantarme, por apoyarme y guiarme, por ser la base que me ayudó a llegar hasta aquí.

Índice general

Agradecimientos	III
Resumen	XIII
1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Objetivo general	3
1.3. Objetivos específicos	3
1.4. Justificación	3
1.4.1. Justificación práctica	3
1.4.2. Justificación metodológica	3
1.5. Límites y alcances	4
1.6. Método de investigación	4
2. Fundamentos de la detección de anomalías	5
2.1. Detección de nomalías	5
2.2. Desafíos en la detección de anomalías	7
2.2.1. Enfoques de detección de anomalías	7
Detección de anomalías supervisada	7
Detección de anomalías semi-supervisada	8
Detección de anomalías no supervisada	8
2.3. Trabajo relacionado	8
2.4. Enfoque sobre el problema	9
2.5. Resumen del capítulo	12
3. Captura y pre-procesamiento de datos	13
3.1. Captura de datos	13
3.2. Pre-procesamiento de datos	14
3.2.1. Normalización	16
Escalado de variables (Feature Scaling o MinMax Scaler)	17
Escalado estándar (Standard Scaler)	17
Escalado sobre el valor máximo	17
Escalado robusto (Robust scaler)	17
3.3. Resumen del capítulo	19
4. Aprendizaje Automático para la detección de anomalías	21
4.1. Aprendizaje Supervisado, Aprendizaje no Supervisado y Aprendizaje Semi-supervisado	21
4.2. Aprendizaje automático para análisis de series de tiempo	23

Índice de figuras

1.1. Muertes por accidentes de tránsito por región en función del tipo de usuario (2013), OMS	2
1.2. Árbol de problemas	2
2.1. Ejemplo de anomalías de punto en un conjunto de datos de 2 dimensiones.	6
2.2. Anomalía contextual t_2 en una serie temporal de temperatura.	6
2.3. Anomalía colectiva correspondiente a una contracción prematura auricular en un electrocardiograma humano.	7
2.4. Método de detección de anomalías propuesto.	10
2.5. Detector de anomalías	11
3.1. Recolección de datos, con intervalo de un segundo.	14
3.2. Soporte para celular de parabrisas, posición horizontal.	14
3.3. Fragmento del conjunto de datos obtenido.	15
3.4. Grafica de los sensores capturados en diferentes posiciones	15
3.5. Histograma de frecuencias del conjunto de datos	16
3.6. Visualización de los parámetros de conducción capturados.	18
3.7. Gráfica resultante de aplicar diferentes tipos de normalizaciones a un conjunto de datos.	19

Índice de cuadros

3.1. Tabla de resultados estadísticos del conjunto de datos.	16
--	----

UNIVERSIDAD MAYOR DE SAN SIMÓN

Resumen

Facultad de Ciencias y Tecnología
Departamento Informática-Sistemas

Licenciatura en Ingeniería de Sistemas

Detección de anomalías de conducción

por Evelyn CUSI LÓPEZ

El presente trabajo describe el desarrollo de un mecanismo de detección de anomalías de manejo, el cual es implementado usando un dispositivo móvil y técnicas de Aprendizaje Automático.

El objetivo es crear una herramienta capaz de encontrar comportamientos anómalos en el manejo de un usuario concreto, teniendo un previo conocimiento de las conductas normales de manejo del mismo. Asimismo se presenta antecedentes de trabajos e investigaciones de la detección de anomalías de manejo de todo el mundo, se analiza los parámetros de manejo de conducción obtenidos por el dispositivo móvil, y se presenta la propuesta para identificar anomalías mediante Redes Neuronales Recurrentes, un método de Aprendizaje Automático que es comunmente utilizado para series de tiempo.

El trabajo cuenta con dos partes principales: un modelo ajustado al comportamiento normal de manejo de un usuario, y un método de detección de anomalías.....

La precisión de detección del método proupuesto en este proyecto es de que fue evaluado con

Capítulo 1

Introducción

El presente documento describe el desarrollo de un método para la detección de anomalías en la conducción. Se propone el uso de técnicas de Aprendizaje Automático para generar un mecanismo que identifique anomalías de manejo, de tal modo que éstas puedan usarse para alertar oportunamente a los conductores y así logren corregir sus conductas de manejo.

La idea principal, es generar un modelo que aprenda el comportamiento normal de conducción de un usuario concreto, para posteriormente detectar de forma autónoma aquellos comportamientos inesperados e informarlos como anomalías, de manera que se pueda evitar un accidente de tránsito o reducir los efectos del mismo.

1.1. Planteamiento del problema

Debido a las graves secuelas que causan sobre las personas y los altos costos económicos asociados a ellos, los accidentes de tránsito se catalogan como un problema social y de salud pública mundial.

Según la Organización Mundial de Salud (OMS) cada año existen aproximadamente 1,25 millones de muertes a causa de accidentes de tránsito, agregando que la mitad de todas estas victimas son peatones, ciclistas y motociclistas (Véase la figura 1.1 pag. 2). Asimismo se puede decir que son una de las causas de muerte más importantes en el mundo, y la principal causa de muerte entre personas de edades comprendidas entre los 15 y los 29 años.

Por otro lado según la Unidad Operativa de Tránsito de Cochabamba los accidentes registrados en 2017 provocaron la muerte de 200 personas y dejaron aproximadamente 2200 heridos.

En la figura 1.2 se muestra las causas por las cuales se ocasiona un accidente de tránsito, se puede observar que gran parte de éstas se deben al factor humano sin embargo hay otras que conllevan factores medio-ambientales y mecánicos, por lo que se hace imposible evitar completamente los mismos.

Es por ello que se hace necesario el contar con mecanismos para prevenir y/o actuar de forma oportuna ante posibles accidentes de tránsito, motivo por el cual el presente trabajo se centra en estudiar los comportamientos de conducción, para así generar




FIGURA 1.1: Muertes por accidentes de tránsito por región en función del tipo de usuario (2013), OMS

alertas al encontrar un comportamiento anómalo en el manejo, de manera que se pueda evitar o en todo caso minimizar los efectos del mismo.

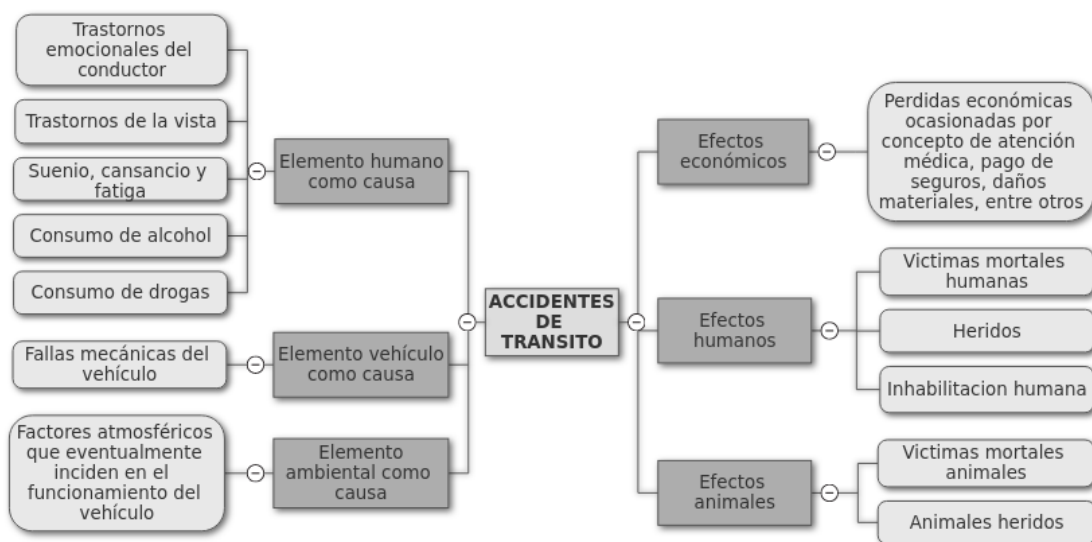


FIGURA 1.2: Árbol de problemas

1.2. **Objetivo general**

El objetivo general del presente trabajo es desarrollar un mecanismo de detección de anomalías de conducción, mediante el uso de un dispositivo móvil y algoritmos de Aprendizaje Automático, con el fin de alertar de forma oportuna el hallazgo de un patrón anómalo en el manejo, tal como cansancio, ebriedad, o problemas de salud, ej, epilepsia.

1.3. **Objetivos específicos**

- Capturar los parámetros de manejo de un conductor mediante el uso de sensores de un dispositivo móvil.
- Escalar los parámetros de manejo mediante técnicas de pre-procesamiento de datos.
- Generar un modelo de aprendizaje automático que se ajuste a un comportamiento normal de manejo.
- Definir un método de detección de anomalías para generar una alerta de conducción anormal.
- Evaluar el método de detección de anomalías con nuevas muestras.

1.4. **Justificación**

Los accidentes de tránsito cobran un número inaceptable de víctimas cada año, especialmente en las regiones más pobres del mundo. Esto se debe a diversos aspectos, pero el principal recae en el bajo nivel de conciencia ciudadana que existe, lo que conlleva a que muchas personas manejen bajo los efectos del alcohol, con exceso de velocidad, manipulando sus dispositivos móviles, entre otros. Por ello este trabajo busca establecer patrones de comportamientos de conducción mediante el uso de un dispositivo móvil y técnicas de Aprendizaje Automático, de manera que se logre realizar una detección de anomalías de manejo oportuna.

1.4.1. **Justificación práctica**

Detectar anomalías de conducción permite generar una alerta oportuna al conductor para que éste logre corregir sus conductas de manejo de forma rápida. De esta manera se podrá evitar accidentes de tránsito o minimizar los efectos del mismo, permitiendo así reducir la cantidad de daños, tanto materiales como personales.

1.4.2. **Justificación metodológica**

El estudio realizado en el desarrollo del presente trabajo de grado permite resaltar la eficiencia de las técnicas de Aprendizaje Automático en la detección de anomalías.

1.5. Límites y alcances

Debido a que la realización de pruebas de campo para ésta investigación es bastante peligrosa, se limitó los ejemplos de conducción anómala a:

Siendo así los experimentos y pruebas se realizaron sólo sobre un pequeño conjunto de ejemplos anómalos, por lo tanto no se espera que éste funcione de manera correcta sobre aquellos ejemplos que no fueron considerados.

1.6. Método de investigación

El presente trabajo de grado se realizó con un enfoque experimental, teniendo como hipótesis la siguiente:

¿Es posible detectar anomalías de conducción mediante el uso de un dispositivo móvil y algoritmos de Aprendizaje Automático?

Capítulo 2

Fundamentos de la detección de anomalías

En este capítulo se aborda los conceptos necesarios que se necesita para comprender la detección de anomalías, así también se expondrá los diferentes proyectos e investigaciones enfocados en la detección de anomalías de conducción.

2.1. Detección de nomalías

Para comprender lo que implica la detección de anomalías, es necesario asimilar lo que és una anomalía y de que maneras estas pueden presentarse. Por lo tanto, se puede decir que las **anomalías**, o valores atípicos, son patrones en los datos que no se ajustan a una noción bien definida de un comportamiento normal.

Las anomalías pueden ser clasificadas dentro de una de las tres siguientes categorías:

1. **Anomalías de punto:** Las anomalías de punto son simplemente instancias únicas y anómalas dentro de un conjunto de datos más grande, es decir, éstas se encuentran separadas del resto de los datos. Por ejemplo, en la Figura 2.1, los puntos o_1 , o_2 y la región O_3 se encuentran fuera de los límites de las regiones normales (N_1 y N_2), y por lo tanto son anomalías puntuales debido a que son diferentes al conjunto de datos normales.

Este tipo de anomalía se considera la más simple y es el foco de la mayoría de las investigaciones enfocadas en la detección de valores atípicos.

2. **Anomalías contextuales (o condicionales):** Estos son puntos que sólo se consideran anómalos en un contexto específico. La noción de este contexto es inducida por la estructura en el conjunto de datos y debe especificarse como parte de la formulación del problema.

Este tipo de anomalías se han explorado con mayor frecuencia en los datos de series de tiempo y datos espaciales. La figura 2.2 muestra un ejemplo de serie temporal de la temperatura mensual de un área en los últimos 5 años, se debe tener en cuenta que la temperatura en el tiempo t_1 es la misma que en el tiempo t_2 , pero se produce en un contexto diferente, por lo tanto t_2 es considerada una anomalía.




FIGURA 2.1: Ejemplo de anomalías de punto en un conjunto de datos de 2 dimensiones.

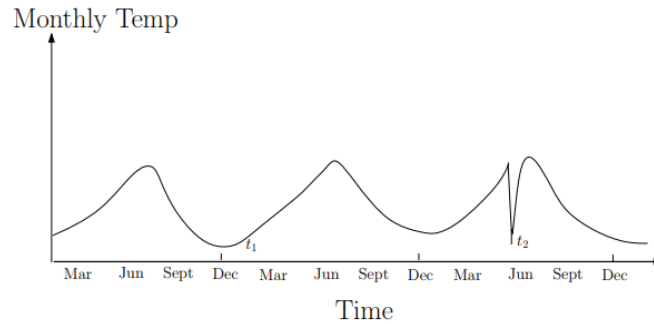


FIGURA 2.2: Anomalía contextual t_2 en una serie temporal de temperatura.

3. **Anomalías colectivas:** Si una colección de instancias de datos relacionadas es anómala con respecto a todo el conjunto de datos, se denomina anomalía colectiva. Las instancias de datos individuales en una anomalía colectiva pueden no ser anomalías por sí mismas, pero su aparición conjunta como una colección es anómala.

La figura 2.3 ilustra un ejemplo que muestra una salida de electrocardiograma humano, se puede notar que la región resaltada en rojo denota una anomalía porque existe el mismo valor bajo durante un tiempo anormalmente prolongado (que corresponde a una Contracción prematura auricular). Se debe tener en cuenta que ese valor bajo por sí mismo no es considerada una anomalía.

En relación a lo expuesto previamente se puede definir como **detección de anomalías**, ó **valores atípicos**, a la identificación de puntos de datos, elementos, observaciones o eventos que no se ajustan al patrón esperado de un grupo determinado.

La detección de anomalías, se usa en distintos dominios de aplicaciones, por ejemplo: procesamiento de imágenes, detección de fraudes de tarjeta, sistemas de detección




FIGURA 2.3: Anomalía colectiva correspondiente a una contracción prematura auricular en un electrocardiograma humano.

de intrusion de red, etcetera.

2.2. Desafíos en la detección de anomalías

En un nivel abstracto, la detección de anomalías puede parecer una tarea simple. Sin embargo puede llegar a ser una tarea muy desafiante. A continuación se presenta algunos de estos desafíos.

- La definición de regiones normales es bastante difícil. En muchos casos, los límites entre las anomalías y los datos normales no son precisos. Por lo tanto, las observaciones normales podrían considerarse anomalías y viceversa.
- Lo que se considera normal hoy en día, puede no ser normal en el futuro.
- La mayor parte de las veces los enfoques para la detección de anomalías en un campo en específico no se pueden utilizar en otro campo.
- La poca disponibilidad de ejemplos positivos (anomalías) para el entrenamiento y validación del modelo de detección de anomalías.

2.2.1. Enfoques de detección de anomalías

Los enfoques que se pueden usar para este propósito se clasifican en las siguientes categorías:

Detección de anomalías supervisada

El uso de técnicas de aprendizaje supervisado requiere la disponibilidad de un conjunto de datos de entrenamiento etiquetados, tanto para clases normales como anómalas. El enfoque principal es construir un modelo predictivo para clases normales vs. anomalías, posteriormente tomar cualquier instancia de datos no visto, comparar con el modelo y determinar a que clase pertenece.

Existen dos principales inconvenientes que surgen con el uso de ésta técnica.

- La cantidad de instancias anómalas es muy inferior a la de las instancias normales, lo que genera un desequilibrio de distribución de clases durante el entrenamiento.
- La obtención de etiquetas precisas y representativas, en particular para la clase de anomalía, es un desafío.

Detección de anomalías semi-supervisada

Estas técnicas requieren un conjunto de entrenamiento con instancias etiquetadas, pero solo para la clase normal, esto hace que su uso sea más aplicable que las técnicas supervisadas, ya que no se requiere etiquetas para la clase anomalía.

El enfoque típico usado en éstas técnicas es construir un modelo para la clase correspondiente al comportamiento normal, y usar el modelo para identificar anomalías en los datos de prueba.

Detección de anomalías no supervisada

Las técnicas que operan de manera no supervisada no requieren datos de entrenamiento, razón por la cual son las más ampliamente utilizadas. Estas técnicas suponen que las instancias normales son mucho más frecuentes que las anomalías en los datos de prueba, en caso de que esta suposición no sea cierta, tales técnicas sufren de una alta tasa de falsas alarmas.

2.3. Trabajo relacionado

La identificación de comportamientos de conducción anormal es una parte indispensable para mejorar la seguridad de conducción, sin embargo, como se describió previamente, ésta no es una tarea sencilla. En los últimos años, se han propuesto varias técnicas para detectar conductas de manejo. Esta sección está dedicada al repaso de las mismas.

Dang-Nhac et al. [20], proponen un sistema combinado que se compone de dos módulos: uno para detectar el tipo de vehículo de los usuarios y el otro para detectar los eventos de conducción instantánea, independientemente de la orientación y la posición de los teléfonos inteligentes, éste sistema logra una precisión promedio del 98.33 % en la detección del tipo del vehículo (automóvil, motocicleta, bicicleta, entre otros) y una precisión promedio de 98.95 % en el reconocimiento de los eventos de conducción de los motociclistas al usar Random Forest como clasificador .

Por otra parte en [21] Ferreira et al. presentan una evaluación cuantitativa de 4 Algoritmos de Aprendizaje Automático (Bayesian Network BN, Artificial Neural Network ANN, Random Forest RF y Support Vector Machine SVM) con diferentes configuraciones, aplicadas en la detección de 7 tipos de eventos de conducción, entre eventos

normales y agresivos, utilizando datos recopilados de 4 sensores de teléfonos inteligentes Android (acelerómetro, aceleración lineal, magnetómetro y giroscopio); dando como resultado que el giroscopio y el acelerómetro son los mejores sensores para detectar eventos de conducción y que Random Forest (RF) es por lejos el Algoritmo de Aprendizaje Automático de mejor rendimiento, seguido de la forma más simple de ANN el Multi Layer Perceptron (MLP).

En [23] proponen el sistema MIROAD el cual muestra que el Dynamic Time Warping (DTW) es un algoritmo válido para detectar maniobras de conducción potencialmente agresivas, donde casi todos los eventos agresivos (97 %) se identificaron correctamente, utilizando el conjunto de sensores T (acelerómetro, giroscopio y el tono de voz). Así también en [24] se propone un sistema enfocado a desarrollar la conciencia del conductor mediante notificaciones en situaciones críticas que pueden desencadenar maniobras de manejo inseguras, mediante un modelo para detectar situaciones peligrosas basadas en Object-Oriented Bayesian Network (OOBN).

Así como los trabajos presentados previamente existe gran cantidad de trabajos ([25], [26], [27], [28], [29]) que usan los sensores de los teléfonos inteligentes (acelerómetro y giroscopio) para la detección de conducción agresiva, esto debido a que se tiene la ventaja de no comprar ni instalar ningún dispositivo y además de ser altamente portátil, sin embargo se depende bastante del rendimiento del receptor GPS y no es aplicable en áreas no disponibles para GPS.

Existen además otros enfoques para la detección de conducción agresiva de un conductor, por ejemplo en [22] proponen un método basado en Convolutional Neural Network (CNN) para detectar la emoción de conducción agresiva, mediante la utilización de imágenes faciales de un conductor obtenidas con una cámara de luz NIR y una cámara térmica.

2.4. Enfoque sobre el problema

Es evidente que éste tema fue ampliamente investigado y que tiene una gran variedad de propuestas de solución, sin embargo la mayoría de estas se basan en la detección mediante técnicas de aprendizaje supervisado, lo cual presenta la gran desventaja de requerir datos etiquetados para generar el modelo de detección; además gran parte de los trabajos relacionados proponen modelos generalizados para la detección y no así modelos específicos por usuarios, lo cual es crucial debido a que cada conductor presenta conductas individuales de manejo y manejan en condiciones distintas, es decir, la conducción de un usuario que circula por avenidas pavimentadas será distinta a la conducción de un usuario que circula por calles empedradas o la conducción de un usuario que circula por avenidas o calles concurridas será distinta a de los usuarios que circulen por calles relativamente descongestionadas.

Es por ello que el presente trabajo propone como solución una aplicación móvil capaz de detectar anomalías de conducción en tiempo real, la cual a grandes rasgos funciona de acuerdo a la Figura 2.4, donde se tiene tres fases principales:

- Captura de datos
- Detector de anomalías
- Generación de alertas

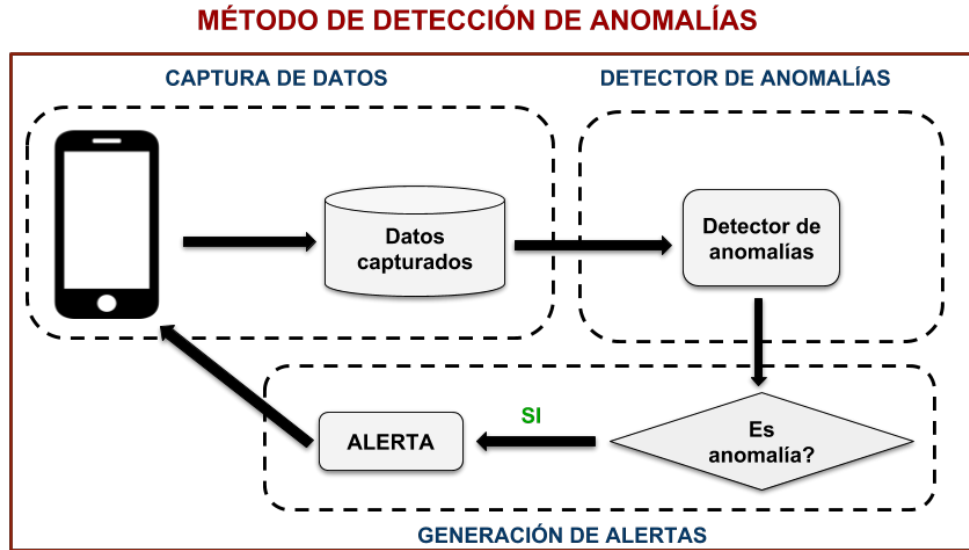


FIGURA 2.4: Método de detección de anomalías propuesto.

de las cuales la Fase dos es la mas importante y es aquella donde recae la importancia de esta investigación, ésta fase presenta cuatro sub-etapas (Ver figura 2.5): pre-procesamiento de los datos, entrenamiento del modelo, validación del modelo y finalmente predicción de nuevos datos.

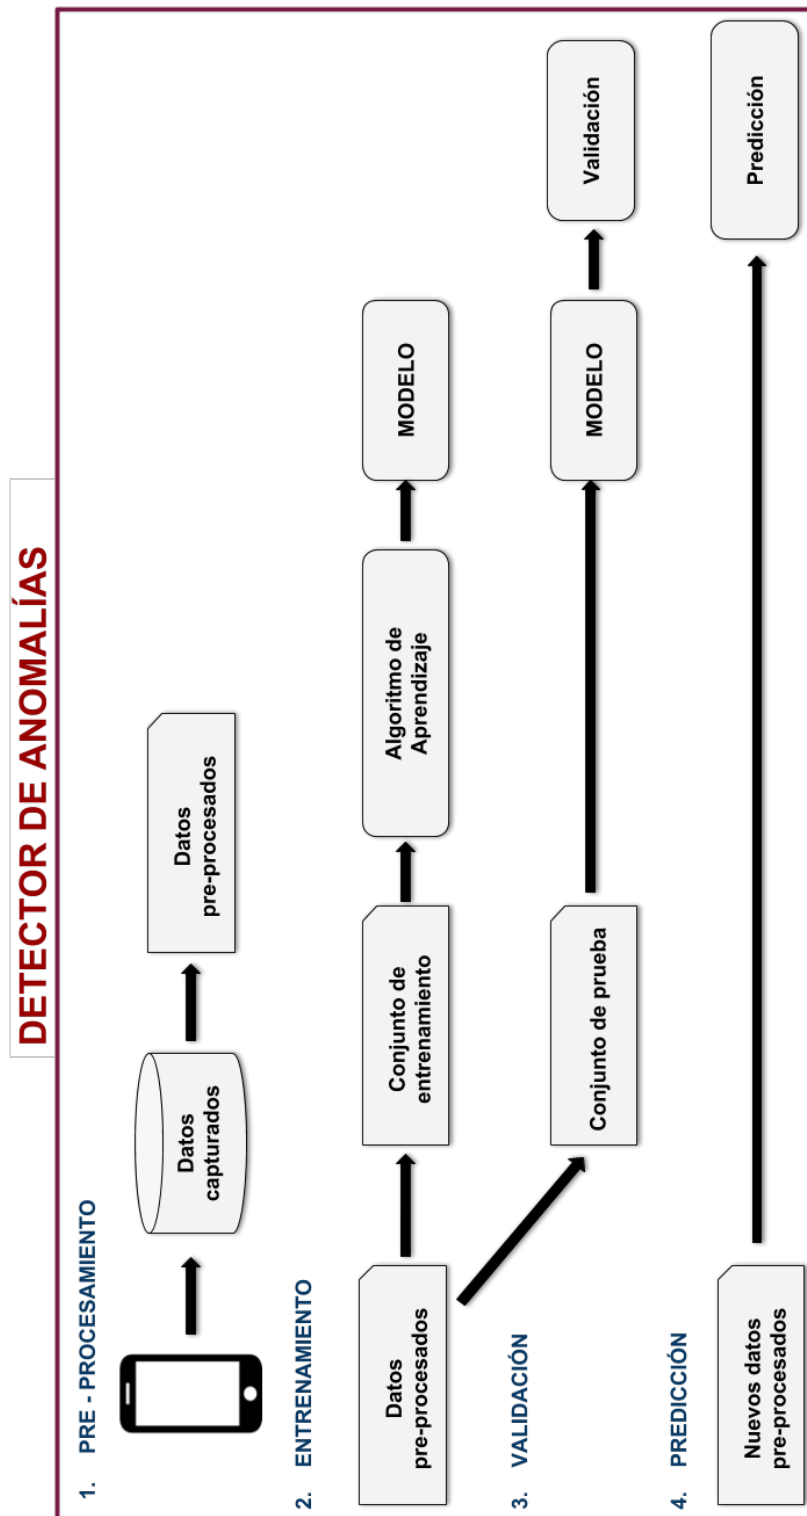


FIGURA 2.5: Detector de anomalías

2.5. Resumen del capítulo

De acuerdo a los conceptos presentados acerca de la detección de anomalías, los desafíos que presenta la detección de las mismas y los trabajos de investigación realizados en este campo hasta la fecha, se propone un método de detección de anomalías de conducción mediante el uso de técnicas de Aprendizaje Automático y el uso de un dispositivo móvil, los mismos serán tratados en profundidad en los siguientes capítulos.

Capítulo 3

Captura y pre-procesamiento de datos

Contar con una gran cantidad de datos en cualquier problema de detección de anomalías es lo que permite generar modelos más precisos, debido a que nunca se sabe qué características pueden dar indicio de una anomalía, contar con múltiples tipos de datos es lo que permite ir más allá de una mera detección de anomalías puntuales y ser capaz de identificar anomalías contextuales o colectivas más sofisticadas. Sin embargo la obtención de estos datos no siempre es una tarea sencilla, por lo que muchas veces se debe encontrar una manera de generar los mismos.

En este capítulo se detallará el método de recolección de datos que se realizará para la presente investigación y las diferentes técnicas de análisis de datos que se aplicará.

3.1. Captura de datos

Actualmente existen varios enfoques para acceder a la información del conductor y del vehículo. En el primer enfoque, un conjunto de sensores y hardware adicional se implementan previamente en el vehículo, por ejemplo, cajas telemáticas (cajas negras provistas por compañías de seguros de automóviles), adaptadores de diagnóstico a bordo (OBD-II) enchufados en el controlador del vehículo red de área (CAN) ([30], [31]), la información registrada por estos dispositivos se puede recuperar o enviar a través de Internet. Sin embargo, esta estrategia requiere que los vehículos instalen dispositivos adicionales, lo que implica un mayor costo. Para superar estos inconvenientes, existe un enfoque alternativo el cual es usar teléfonos inteligentes para recopilar datos a través de un conjunto de sensores integrados, tales como sensores inerciales (acelerómetros y giroscopios), sistemas de posicionamiento global (GPS), magnetómetros, micrófonos, sensores de imagen (cámaras), sensores de luz, sensores de proximidad, sensores de dirección (brújula), entre otros.

Para el presente trabajo de grado se eligió el uso de teléfonos inteligentes para acceder a la información del tipo de conducción, por las razones que se presentaron anteriormente, con este enfoque se desarrolló una aplicación móvil basada en Android para recopilar datos de los sensores: acelerómetro y giroscopio, en intervalos de 1 segundo, los cuales en una primera instancia serán almacenados de manera interna en el dispositivo móvil. (Ver Figura 3.1)




FIGURA 3.1: Recolección de datos, con intervalo de un segundo.

Para la captura de datos se usó un soporte para celular de parabrisas como se ve en la Figura 3.2; se realizó la captura en dos posiciones distintas (vertical y horizontal).



FIGURA 3.2: Soporte para celular de parabrisas, posición horizontal.


Cada captura, independientemente de la posición en la que se realizó, dió como resultado un conjunto de datos (dataset), donde por cada tiempo T (1 seg.) se tiene seis variables: acelerómetro en X (acc x), acelerómetro en Y (acc y), acelerómetro en Z (acc z), giroscopio en X (gyr x), giroscopio en Y (gyr y) y giroscopio en Z (gyr z). En la Figura 3.3 se aprecia un fragmento del conjunto de datos que se obtuvo en una captura.

3.2. Pre-procesamiento de datos

Como se indicó en la anterior sección, se realizó la captura de datos del manejo de un usuario (conductor), de forma vertical y horizontal, a continuación se analizará las diferencias entre ellos.

_id	acc_x	acc_y	acc_z	gyr_x	gyr_y	gyr_z
	Filter	Filter	Filter	Filter	Filter	Filter
1	-0.4353179...	9.60725402...	1.84175109...	9.15527343...	-0.0020294...	0.00770568...
2	-1.1603393...	9.73767089...	1.84773254...	-0.0500488...	0.02827453...	0.00379943...
3	-0.3013153...	9.57853698...	1.90994262...	0.00070190...	-0.0008697...	0.00354003...
4	-0.3479614...	9.59648132...	1.89201354...	0.00035095...	-0.0009918...	0.00372314...

FIGURA 3.3: Fragmento del conjunto de datos obtenido.



(A) Captura de datos en horizontal

(B) Captura de datos en vertical

FIGURA 3.4: Grafica de los sensores capturados en diferentes posiciones

En la Figura 3.4 se muestra fragmentos de las capturas obtenidas por el dispositivo móvil del manejo de un mismo usuario desde diferentes posiciones.

Si bien los valores capturados, son muy similares entre sí, los datos que fueron capturados con el dispositivo móvil en posición horizontal, presentan menos ruido, esto debido a que esta posición favorece la inercia del dispositivo cuando el vehículo está en movimiento, lo cual es una gran ventaja frente a los datos que fueron capturados de forma vertical, ya que estos fueron más susceptibles a sacudirse mientras el vehículo se desplazaba haciendo que los valores capturados en esta posición presenten valores de movimiento no sólo del vehículo sino también del dispositivo móvil, lo cual no es lo que se busca en el presente trabajo.

Por las razones presentadas en el anterior párrafo se decidió trabajar con los datos capturados con el dispositivo móvil en posición horizontal.

Para conseguir un análisis más profundo de los datos capturados durante la conducción de un vehículo, a continuación se presenta una tabla con los parámetros estadísticos (Valor mínimo, Valor máximo, Media, Mediana, Desviación estándar) resultantes para cada columna de datos capturada (Tabla 3.1).

	ACC-X	ACC-Y	ACC-Z	GYR-X	GYR-Y	GYR-Z
Min	-16.1556	-11.5167	-11.2487	-3.0617	-3.2679	-4.7595
Max	15.5559	11.3349	15.2552	4.3997	2.3482	2.9745
Media	9.5361	-0.7939	-0.4447	0.0015	0.0003	-0.0011
Mediana	9.7751	-0.9049	-0.4820	-0.0001	6.1035e-05	6.1035e-05
Des. est.	1.7220	1.3904	0.9007	0.0905	0.0857	0.1042

CUADRO 3.1: Tabla de resultados estadísticos del conjunto de datos.

Con la información proporcionada por la tabla ahora resulta más sencillo realizar un análisis del conjunto de datos, en primer lugar se evidencia que los valores obtenidos durante la captura, con el uso del dispositivo móvil, se presentan entre rangos de valores muy distintos, se puede observar por ejemplo, que el valor del acelerómetro en X oscila entre los valores de -16 y 15 aproximadamente, mientras que los valores del giroscopio en X se encuentran entre -3 y 4, lo cual representa un problema debido a que ésta diferencia de rangos puede generar más peso en unos datos que en otros.

Para apreciar de una manera más gráfica el problema expuesto con anterioridad a continuación se presenta histogramas de las frecuencias de valores por cada tipo de parámetros que existe en el conjunto de datos. (Ver Figura 3.5)




FIGURA 3.5: Histograma de frecuencias del conjunto de datos

Para solucionar este problema existe diversas técnicas, las cuales se abordarán en la siguiente sección.

3.2.1. Normalización

La normalización de datos es un proceso o técnica para comprimir o extender los valores de una variable para que estén en un rango definido, lo cual hace que muchos

algoritmos de Aprendizaje Automático funcionen mejor, sin embargo, una mala aplicación de este proceso, o una elección descuidada del método de normalización puede arruinar los datos.

A continuación se presenta algunos ejemplos de los métodos de normalización más utilizados.

Escalado de variables (Feature Scaling o MinMax Scaler)

En este método, cada entrada se normaliza entre unos límites definidos:

$$x_{normalizado} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (3.1)$$

Presenta el problema de que comprime los datos de entrada entre unos límites fijos, que por lo general son 0 y 1. Esto quiere decir que si existe ruido, éste va a ser ampliado, lo que hace que este método no sea adecuado para señales estables.

Escalado estándar (Standard Scaler)

Es un método alternativo al escalado de variables, consiste en restar a cada dato la media de la variable y dividirlo por la desviación típica.

$$x_{normalizado} = \frac{x - x_{media}}{x_{desvSt}} \quad (3.2)$$

Éste método si sería adecuado para normalizar señales estables, no obstante, tanto la media como la desviación estándar son muy sensibles a valores anómalos. Una alternativa de solución de esto sería la eliminación de anomalías antes de realizar la normalización.

Escalado sobre el valor máximo

El siguiente método, presenta la idea de escalar los datos dividiendo éstos entre su máximo valor.

Escalado robusto (Robust scaler)

El escalado robusto consiste en eliminar la mediana y escala los datos de acuerdo con el rango de intercuartil (IQR). Este método es robusto para valores atípicos.

A continuación se elaborará un análisis para decidir que técnica de normalización es la más adecuada para escalar los parámetros de conducción capturados, en la Figura 3.6 se puede apreciar una fracción del conjunto de datos capturado, la cual es la base con la que se realizará el análisis comparativo con los distintos tipos de normalización.

El primer tipo de escalado que se realizó sobre el conjunto de datos capturados fue el **escalado de variables**, el cual se realizó entre los límites 0 y 1, los resultados obtenidos se muestran en la figura 3.7a, donde se puede apreciar que los valores del acelerómetro, en sus tres ejes, no se ven deformados después de haber sido escalados con ésta técnica y

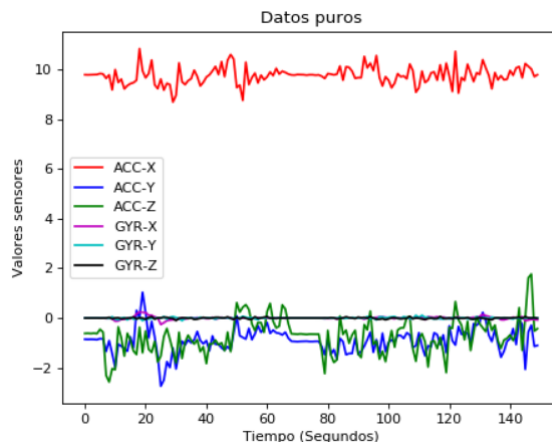


FIGURA 3.6: Visualización de los parámetros de conducción capturados.

los valores del giroscopio, los cuales son más estables, no se tornan deformados, lo cual es una ventaja debido a que los valores de ruido no son ampliados como se esperaba que lo hicieran.

La segunda técnica de normalización que se aplicó sobre los datos fue el **escalado estándar**, el resultado se puede apreciar en la figura 3.7b, observando detalladamente los resultados se puede evidenciar que los valores del acelerómetro son levemente deformados, sin embargo aún es posible trabajar con ellos, a pesar de esto los valores del giroscopio amplían en exceso el ruido existente, deformando completamente la señal estable que presenta en sus tres ejes.

Para la tercera normalización de datos se aplicó la técnica de **escalado sobre el valor máximo**, los resultados se presentan de manera similar a los resultados que se obtuvo al aplicar el escalado de variables, con la diferencia de que en éste caso se obtiene valores negativos tanto para el acelerómetro en Y y en Z, como se puede ver en la figura 3.7c.

La última técnica aplicada es el **escalado robusto** donde se obtiene los peores resultados de los cuatro métodos de normalización que se aplicaron sobre el conjunto de datos, como se puede observar en la figura 3.7d, esto debido a que los valores resultantes para los parámetros del acelerómetro tanto en X, Y y Z se presentan reducidos frente a los demás, lo cual no refleja el comportamiento real de los datos, en cuanto a los valores del giroscopio se logra ver claramente que el ruido presentado en estas señales estables se amplía en exceso, lo cual deforma totalmente los datos.

Para decidir el mejor método de normalización que se puede aplicar a los datos capturados, primero se descartará completamente el **método de escalado robusto** debido a que los resultados que presentó fueron totalmente desalentadores ya que deformaba los datos y no reflejaba el comportamiento real de los mismos, por otra parte el **método de escalado estándar** también será descartado debido a que amplía el ruido en exceso

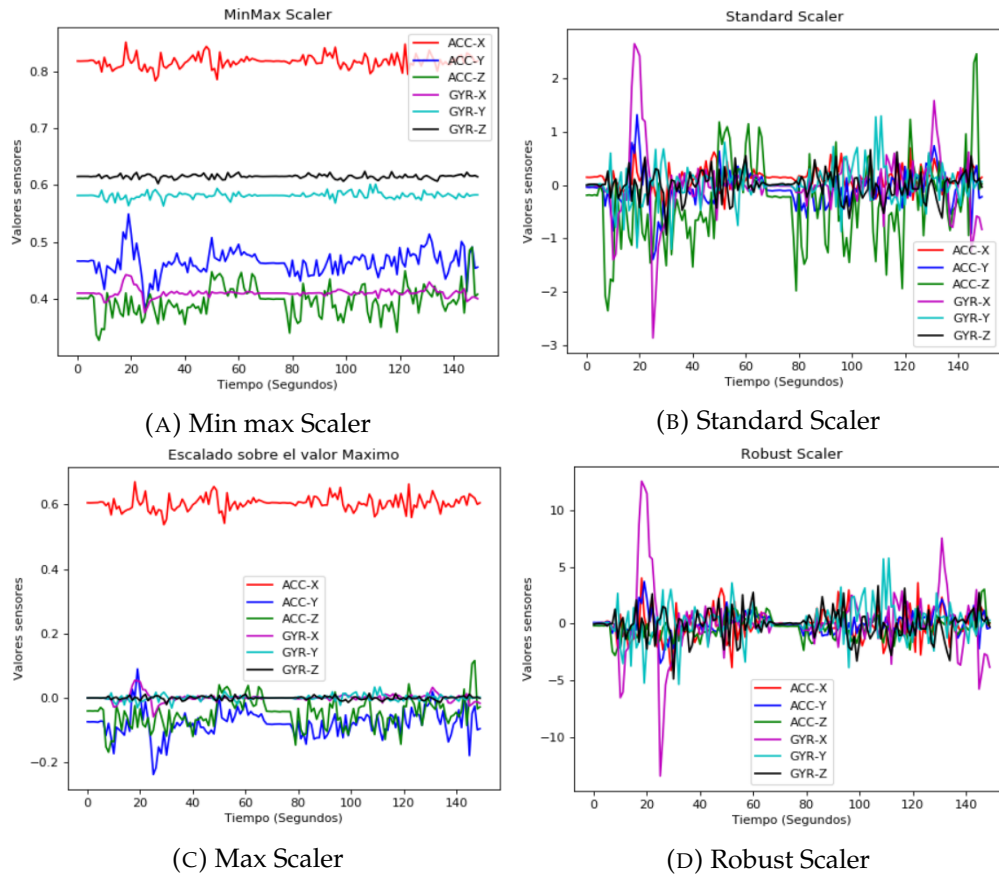


FIGURA 3.7: Gráfica resultante de aplicar diferentes tipos de normalizaciones a un conjunto de datos.

de los valores del giroscopio, quedando como únicas alternativas los métodos de **escalado de variables** y el **escalado sobre el valor máximo** los cuales presentan resultados similares como se puede apreciar tanto en el análisis realizado previamente como en la figura 3.7, sin embargo presentan la diferencia de que uno de éstos obtiene resultados con valores negativos y el otro valores entre los límites 0 y 1, considerando que al momento de generar el modelo de Aprendizaje Automático los valores negativos podrían presentar una desventaja se eligió el método de **escalado de variables** ya que este solo presentará valores positivos.

3.3. Resumen del capítulo

En este capítulo se ha descrito la forma en la que se realizó la captura de datos de conducción, el pre-procesamiento del conjunto de datos mediante técnicas estadísticas y visuales y finalmente la elección de un método de normalización para comprimir los valores en un rango definido, para que de ésta manera estos valores sean una mejor entrada para el algoritmo de aprendizaje automático que se aplicará en el siguiente capítulo.

Capítulo 4

Aprendizaje Automático para la detección de anomalías

El término Aprendizaje Automático se refiere a la detección automática de patrones significativos dentro de un conjunto de datos [32]. En las últimas décadas se ha convertido en una herramienta común en casi cualquier tarea que requiera la extracción de información de gran cantidad de datos, por lo cual se ha convertido en una de las áreas de más rápido crecimiento de la informática.

Si bien el Aprendizaje Automático puede resolver algunos problemas que son resueltos con algoritmos tradicionales, ha superado a éstos en problemas tales como el reconocimiento de imágenes, voz, lenguaje, escritura, juegos, robótica, análisis de datos, análisis de series de tiempo, etc. Desde esta perspectiva, se espera que mediante la aplicación del Aprendizaje Automático se pueda generar un modelo que se ajuste a un comportamiento normal esperado para un usuario.

4.1. Aprendizaje Supervisado, Aprendizaje no Supervisado y Aprendizaje Semi-supervisado

Existen diversas formas de clasificar los paradigmas de aprendizaje que existen, sin embargo en el presente trabajo sólo se tratarán el supervisado, el no supervisado y el semi-supervisado.

El **Aprendizaje Supervisado** es aquel que cuenta con variables de entrada (X) y una variable de salida (Y), este tipo de aprendizaje utiliza un algoritmo para aprender la función de mapeo desde la entrada hasta la salida.

$$Y = f(X) \quad (4.1)$$

El objetivo de este tipo de aprendizaje es aproximar la función de mapeo de tal forma que cuando tenga datos de entrada nuevos (X) pueda predecir las variables de salida (Y) para esos datos.

Este tipo de aprendizaje aborda dos tipos de problemas: clasificación y regresión. Los problemas de **Clasificación** son aquellos donde la variable de salida es una categoría, como por ejemplo: "Rojo", "Azul", o "Sano", "Enfermo", por otra parte en los problemas de **Regresión** la variable de salida es un valor real, tal como: "precio" o "altura".

Algunos de los tipos de problemas más comunes contruidos sobre la clasificación y la regresión incluyen la recomendación y la predicción de series temporales.

Por otro lado el **Aprendizaje no Supervisado** es aquel donde sólo se cuenta con datos de entrada (X) y no hay variables de salida correspondientes, su objetivo principal consiste en modelar la estructura o distribución subyacente en los datos para aprender más acerca de los mismos.

En cuanto a los problemas del Aprendizaje sin supervisión, pueden ser agrupados en dos: agrupamiento y asociación. El **Agrupamiento** es aquel donde se desea descubrir las agrupaciones inherentes en el conjunto de datos, como por ejemplo agrupar clientes por comportamiento de compra. Por otra parte la **Asociación** es aquella que desea descubrir reglas que describen grandes porciones de sus datos, por ejemplo las personas que compran X también tienden a comprar Y. Algunos de los algoritmos de aprendizaje sin supervisión más populares son: K-means (para problemas de agrupamiento) y algoritmo Apriori (para problemas de aprendizaje de reglas de asociación).

Por último se encuentra el **Aprendizaje Semi-supervisado**, el cual abarca aquellos problemas donde se tiene gran cantidad de datos de entrada (X) y sólo algunos de los datos están etiquetados (Y). Este tipo de problemas se encuentran entre el aprendizaje supervisado y el no supervisado, además es importante señalar que muchos de los problemas de Aprendizaje Automático en el mundo real se encuentran en esta área, esto debido a que resulta costoso o puede requerir mucho tiempo etiquetar el conjunto de datos, mientras que los datos no etiquetados son baratos, además de ser fáciles de recolectar y almacenar. Este tipo de problemas pueden usar una combinación de técnicas supervisadas y no supervisadas para ser resueltos.

Dado que los métodos de Aprendizaje Supervisado requieren una gran cantidad de datos de entrenamiento etiquetados, es importante aclarar que la recolección de muestras negativas (conducción anómala) es difícil y riesgosa para este estudio en particular; además el enfoque supervisado presenta una limitación potencial, la cual es: la detección de nuevos patrones atípicos, esto debido a que el modelo resultante sólo esta entrenado para reconocer un conjunto limitado de patrones anómalos, por lo cual al momento en que se presente un nuevo patrón este modelo será incapaz de reconocerlo.

Por otra parte el enfoque sin supervisión tiene la ventaja de no requerir información etiquetada, sin embargo a menudo sufre altas tasas de falsas alarmas y bajas tasas de detección [33].

En muchas aplicaciones, incluyendo la del presente trabajo de grado, los ejemplos normales son fáciles de conseguir, mientras que los anómalos son bastante difíciles de obtener, en consecuencia, para la realización de este estudio, se ha optado por la aplicación del enfoque Semi-supervisado. De esta manera, como se mencionó en el Capítulo 2, el enfoque de **detección de anomalías Semi-supervisado** sólo dispone de muestras normales en el conjunto de entrenamiento; es decir, no se puede obtener información sobre anomalías, por lo tanto las muestras desconocidas se clasifican como valores atípicos, siempre y cuando su comportamiento sea muy diferente al de las muestras normales ya

conocidas. Por lo tanto en este trabajo, se propone un método de detección de anomalías de conducción semi-supervisado que consta de dos componentes: un modelo ajustado al comportamiento normal de manejo de un usuario y un método de desviación estándar para la detección de valores atípicos.

Para la generación del modelo de detección de anomalías se optó por algoritmos de aprendizaje automático enfocados en series de tiempo, dado que los datos, de los sensores capturados por el dispositivo móvil, dependen del tiempo en el que fueron capturados, a continuación se presenta algunos algoritmos de aprendizaje automático supervisado para series de tiempo.

4.2. Aprendizaje automático para análisis de series de tiempo

Para entender la importancia de las series de tiempo se puede tomar la siguiente analogía, los seres humanos no comienzan a pensar desde cero cada segundo, por lo que al leer un documento se comprende cada palabra basándose en la comprensión de las palabras anteriores, es decir, no se elimina todo y se empieza a pensar de cero cada vez, dada ésta afirmación se puede decir que los pensamientos de los seres humanos tienen persistencia.

Las redes neuronales tradicionales no tienen persistencia de los datos, lo que para algunos problemas en concreto, incluyendo el que se aborda en este trabajo, es una gran deficiencia. Con el fin de resolver este tipo de problemas aparecen las Redes Neuronales Recurrentes (RNN), las cuales son un tipo de red neuronal artificial propuesta en los años 80 ([34], [35], [36]) diseñada para reconocer patrones en secuencias de datos, como texto, genomas, escritura a mano, datos de series de tiempo numéricos que emanan de sensores, entre otros.

La estructura de las RNN es similar a la de un perceptrón multicapa estándar, con la diferencia de que permite conexiones entre unidades ocultas asociadas con un retardo de tiempo; a través de estas conexiones, el modelo puede retener información sobre el pasado, lo que le permite descubrir correlaciones temporales entre eventos que están muy lejos unos de otros en los datos.

Las RNN tienen una cierta memoria de lo que sucedió anteriormente en una secuencia de datos, esto ayuda al sistema a ganar contexto de los datos. Teóricamente se dice que las RNN tienen memoria infinita, es decir, este tipo de redes tienen la capacidad de mirar hacia atrás indefinidamente; sin embargo en la práctica solo se puede mirar atrás unos últimos pasos.

LSTM está diseñado para obtener un flujo constante de errores en el tiempo y proteger este flujo de errores

Bibliografía

- [1] DANG-NHAC, L., DUC-NHAN, N., THI-HAU, N., y HA-NAM, N. Vehicle mode and driving activity detection based on analyzing sensor data of smartphones, *Sensors* v. 18, 4 (2018), 1036.
- [2] FERREIRA, J., CARVALHO, E., FERREIRA, B., DE SOUZA, C., SUHARA, Y., PENTLAND, A., y PESSIN, G. Driver behavior profiling: An investigation with different smartphone sensors and machine learning, *PLoS One* v. 12, 4 (2017), e0174959.
- [3] WHO-LEE, K., SIK-YOON, H., MIN-SONG, J., y RYOUNG-PARK, K. Convolutional Neural Network-Based Classification of Driver's Emotion during Aggressive and Smooth Driving Using Multi-Modal Camera Sensors, *Sensors* v. 18, 4 (2018), 957.
- [4] JOHNSON, D., y TRIVEDI, M. Driving Style Recognition Using a Smartphone as a Sensor Platform. En: Intelligent Transportation Systems (ITSC), 2011 14th International IEEE Conference, 2011. p. 1609–1615.
- [5] KRIDALUKMANA, R., YAN-LU, H., y NADERPOUR, M. An Object Oriented Bayesian Network Approach for Unsafe Driving Maneuvers Prevention System, 2017 12th International IEEE Conference.
- [6] BHOYAR, V., LATA, P., KATKAR, J., PATIL, A., y JAVALE, D. Symbian Based Rash Driving Detection System. *Int. J. Emerg. Trends Technol. Comput. Sci.* 2013;2:124–126.
- [7] CHEN, Z., YU, J., ZHU, Y., CHEN, Y., y LI, M. D3: Abnormal Driving Behaviors Detection and Identification Using Smartphone Sensors; Proceedings of the 12th Annual IEEE International Conference on Sensing, Communication, and Networking; Seattle, WA, USA. 22–25 de Junio 2015; pp. 524–532.
- [8] EREN, H., MAKINIST, S., AKIN, E., y YILMAZ, A. Estimating Driving Behavior by a Smartphone; Proceedings of the Intelligent Vehicles Symposium; Alcalá de Henares, España. 3–7 de Junio 2012; pp. 234–239.
- [9] BOONMEE, S., y TANGAMCHIT, P. Portable Reckless Driving Detection System; Proceedings of the 6th IEEE International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology; Pattaya, Chonburi, Tailandia. 6–9 de Mayo 2009; pp. 412–415.
- [10] KOH, D.-W., y KANG, H.-B. Smartphone-Based Modeling and Detection of Aggressiveness Reactions in Senior Drivers; Proceedings of the IEEE Intelligent Vehicles Symposium; Seoul, Korea. 28 de Junio – 1 de Julio 2015; pp. 12–17.

- [11] ZALDIVAR, J., CALAFATE, C.T., CANO, J.C., y MANZONI, P. Providing accident detection in vehicular networks through OBD-II devices and Android-based smartphones; Proceedings of the 2011 IEEE 36th Conference on Local Computer Networks; Bonn, Alemania. 4–7 de Octubre 2011; pp. 813–819.
- [12] ARAUJO, R., IGREJA, A., DE CASTRO R., y ARAUJO, R. Driving coach: A smartphone application to evaluate driving efficient patterns; Proceedings of the 2012 IEEE Intelligent Vehicles Symposium (IV); Alcala de Henares, España. 3–7 de Junio 2012; pp. 1005–1010.
- [13] SHAI, S., y SHAI, B. Understanding Machine Learning: From Theory to Algorithms (2014).
- [14] XUE, Z., SHANG, Y., y FENG, A. Semi-supervised outlier detection based on fuzzy rough C-means clustering. *Mathematics and Computers in Simulation*, vol. 80, no. 9, pp. 1911–1921.
- [15] RUMELHART, D. E., HINTON, G. E., y WILLIAMS, R. J. (1986). Learning representations by backpropagating errors. *Nature*, 323(6088), 533–536.
- [16] ELMAN, J. (1990). Finding structure in time. *Cognitive Science*, 14(2), 179–211.
- [17] WERBOS, P. J. (1988). Generalization of backpropagation with application to a recurrent gas market model. *Neural Networks*, 1(4), 339–356.