

UNIVERSIDAD MAYOR DE SAN SIMÓN

PROYECTO DE GRADO

Detección de anomalías de conducción

Autor:
Evelyn CUSI LÓPEZ

Tutor:
Dr. Eduardo DI SANTI

*Un proyecto de grado presentado en cumplimiento de los requisitos
para el título de Licenciatura en Ingeniería de Sistemas*

en la

Carrera de Ingeniería de Sistemas
Departamento Informática-Sistemas

30 de septiembre de 2019

Agradecimientos

Le agradezco a Dios por haberme acompañado y guiado a lo largo de mi carrera, por ser mi fortaleza en los momentos de debilidad y por brindarme una vida llena de aprendizajes, experiencias y sobre todo felicidad.

A mi madre, por estar conmigo, por enseñarme a crecer y a levantarme, por apoyarme y guiarme, por ser la base que me ayudó a llegar hasta aquí.

Índice general

Agradecimientos	III
Resumen	XIII
1. Introducción	1
1.1. Planteamiento del problema	1
1.2. Objetivo general	3
1.3. Objetivos específicos	3
1.4. Justificación	3
1.4.1. Justificación práctica	3
1.4.2. Justificación metodológica	3
1.5. Límites y alcances	4
1.6. Método de investigación	4
2. Fundamentos de la detección de anomalías	5
2.1. Detección de nomalías	5
2.2. Desafíos en la detección de anomalías	7
2.2.1. Enfoques de detección de anomalías	7
Detección de anomalías supervisada	7
Detección de anomalías semi-supervisada	8
Detección de anomalías no supervisada	8
2.3. Trabajo relacionado	8
2.4. Enfoque sobre el problema	9
2.5. Resumen del capítulo	10
3. Captura y preparación de datos	11
3.1. Captura de datos	11
3.2. Preparación de datos	12
3.2.1. Selección de datos	13
3.3. Pre-procesamiento de datos	14
3.3.1. Limpieza de datos	14
Manejo de valores ausentes	14
Eliminar ruido (suavizado) de los datos	15
Fusión o integración de datos	17
Transformación de datos	18
Reducción de datos	19
3.4. Resumen del capítulo	26

4. Aprendizaje Automático para la detección de anomalías	27
4.1. Aprendizaje Supervisado, Aprendizaje no Supervisado y Aprendizaje Semi-supervisado	27
4.2. Modelo del comportamiento normal	31
4.3. Aprendizaje automático para análisis de series de tiempo	31

Índice de figuras

1.1. Muertes por accidentes de tránsito por región en función del tipo de usuario (2013), OMS	2
1.2. Árbol de problemas	2
2.1. Ejemplo de anomalías de punto en un conjunto de datos de 2 dimensiones.	6
2.2. Anomalía contextual t_2 en una serie temporal de temperatura.	6
2.3. Anomalía colectiva correspondiente a una contracción prematura auricular en un electrocardiograma humano.	7
2.4. Método de detección de anomalías propuesto.	10
3.1. Recolección de datos, con intervalo de un segundo.	12
3.2. Soporte para celular de parabrisas, posición horizontal.	12
3.3. Fragmento del conjunto de datos obtenido.	13
3.4. Gráfica de los sensores capturados en diferentes posiciones	14
3.5. Histograma de frecuencias del conjunto de datos	16
3.6. Tabla de resultados estadísticos del conjunto de datos.	16
3.7. Regla 68-95-99.7	17
3.8. Regla 68-95-99.7 aplicada a los valores de los sensores del acelerómetro en Y.	18
3.9. División del conjunto de entrenamiento.	21
3.10. Visualización de los parámetros de conducción capturados.	22
3.11. Gráfica resultante de aplicar diferentes tipos de normalizaciones a un conjunto de datos.	23
3.12. Gráfico de la varianza vs el número de componentes.	26

Índice de cuadros

3.1. Tabla de división del conjunto de datos.	21
3.2. Tabla con estadísticas descriptivas de los datos escalados con diferentes técnicas.	25
4.1. Tabla con diferentes tamaños de series de tiempo para 3 y 4 componentes principales.	30

UNIVERSIDAD MAYOR DE SAN SIMÓN

Resumen

Facultad de Ciencias y Tecnología
Departamento Informática-Sistemas

Licenciatura en Ingeniería de Sistemas

Detección de anomalías de conducción

por Evelyn CUSI LÓPEZ

El presente trabajo describe el desarrollo de un mecanismo de detección de anomalías de manejo, el cual es implementado usando un dispositivo móvil y técnicas de Aprendizaje Automático.

El objetivo es crear una herramienta capaz de encontrar comportamientos anómalos en el manejo de un usuario concreto, teniendo un previo conocimiento de las conductas normales de manejo del mismo. Asimismo se presenta antecedentes de trabajos e investigaciones de la detección de anomalías de manejo de todo el mundo, se analiza los parámetros de manejo de conducción obtenidos por el dispositivo móvil, y se presenta la propuesta para identificar anomalías mediante Redes Neuronales Recurrentes, un método de Aprendizaje Automático que es comunmente utilizado para series de tiempo.

El trabajo cuenta con dos partes principales: un modelo ajustado al comportamiento normal de manejo de un usuario, y un método de detección de anomalías.....

La precisión de detección del método proupuesto en este proyecto es de que fue evaluado con

Capítulo 1

Introducción

El presente documento describe el desarrollo de un método para la detección de anomalías en la conducción. Se propone el uso de técnicas de Aprendizaje Automático para generar un mecanismo que identifique anomalías de manejo, de tal modo que éstas puedan usarse para alertar oportunamente a los conductores y así logren corregir sus conductas de manejo.

La idea principal, es generar un modelo que aprenda el comportamiento normal de conducción de un usuario concreto, para posteriormente detectar de forma autónoma aquellos comportamientos inesperados e informarlos como anomalías, de manera que se pueda evitar un accidente de tránsito o reducir los efectos del mismo.

1.1. Planteamiento del problema

Debido a las graves secuelas que causan sobre las personas y los altos costos económicos asociados a ellos, los accidentes de tránsito se catalogan como un problema social y de salud pública mundial.

Según la Organización Mundial de Salud (OMS) cada año existen aproximadamente 1,25 millones de muertes a causa de accidentes de tránsito, agregando que la mitad de todas estas victimas son peatones, ciclistas y motociclistas (Véase la figura 1.1 pag. 2). Asimismo se puede decir que son una de las causas de muerte más importantes en el mundo, y la principal causa de muerte entre personas de edades comprendidas entre los 15 y los 29 años.

Por otro lado según la Unidad Operativa de Tránsito de Cochabamba los accidentes registrados en 2017 provocaron la muerte de 200 personas y dejaron aproximadamente 2200 heridos.

En la figura 1.2 se muestra las causas por las cuales se ocasiona un accidente de tránsito, se puede observar que gran parte de éstas se deben al factor humano sin embargo hay otras que conllevan factores medio-ambientales y mecánicos, por lo que se hace imposible evitar completamente los mismos.

Es por ello que se hace necesario el contar con mecanismos para prevenir y/o actuar de forma oportuna ante posibles accidentes de tránsito, motivo por el cual el presente trabajo se centra en estudiar los comportamientos de conducción, para así generar




FIGURA 1.1: Muertes por accidentes de tránsito por región en función del tipo de usuario (2013), OMS

alertas al encontrar un comportamiento anómalo en el manejo, de manera que se pueda evitar o en todo caso minimizar los efectos del mismo.

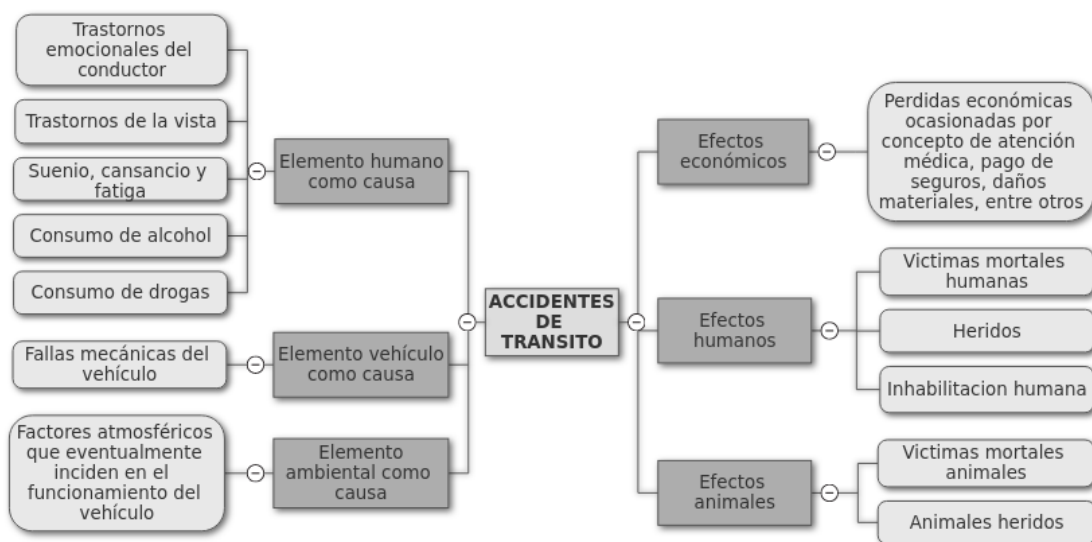


FIGURA 1.2: Árbol de problemas

1.2. **Objetivo general**

El objetivo general del presente trabajo es desarrollar un mecanismo de detección de anomalías de conducción, mediante el uso de un dispositivo móvil y algoritmos de Aprendizaje Automático, con el fin de alertar de forma oportuna el hallazgo de un patrón anómalo en el manejo, tal como cansancio, ebriedad, o problemas de salud, ej, epilepsia.

1.3. **Objetivos específicos**

- Capturar los parámetros de manejo de un conductor mediante el uso de sensores de un dispositivo móvil.
- Escalar los parámetros de manejo mediante técnicas de pre-procesamiento de datos.
- Generar un modelo de aprendizaje automático que se ajuste a un comportamiento normal de manejo.
- Definir un método de detección de anomalías para generar una alerta de conducción anormal.
- Evaluar el método de detección de anomalías con nuevas muestras.

1.4. **Justificación**

Los accidentes de tránsito cobran un número inaceptable de víctimas cada año, especialmente en las regiones más pobres del mundo. Esto se debe a diversos aspectos, pero el principal recae en el bajo nivel de conciencia ciudadana que existe, lo que conlleva a que muchas personas manejen bajo los efectos del alcohol, con exceso de velocidad, manipulando sus dispositivos móviles, entre otros. Por ello este trabajo busca establecer patrones de comportamientos de conducción mediante el uso de un dispositivo móvil y técnicas de Aprendizaje Automático, de manera que se logre realizar una detección de anomalías de manejo oportuna.

1.4.1. **Justificación práctica**

Detectar anomalías de conducción permite generar una alerta oportuna al conductor para que éste logre corregir sus conductas de manejo de forma rápida. De esta manera se podrá evitar accidentes de tránsito o minimizar los efectos del mismo, permitiendo así reducir la cantidad de daños, tanto materiales como personales.

1.4.2. **Justificación metodológica**

El estudio realizado en el desarrollo del presente trabajo de grado permite resaltar la eficiencia de las técnicas de Aprendizaje Automático en la detección de anomalías.

1.5. Límites y alcances

Debido a que la realización de pruebas de campo para ésta investigación es bastante peligrosa, se limitó los ejemplos de conducción anómala a:

Siendo así los experimentos y pruebas se realizaron sólo sobre un pequeño conjunto de ejemplos anómalos, por lo tanto no se espera que éste funcione de manera correcta sobre aquellos ejemplos que no fueron considerados.

1.6. Método de investigación

El presente trabajo de grado se realizó con un enfoque experimental, teniendo como hipótesis la siguiente:

¿Es posible detectar anomalías de conducción mediante el uso de un dispositivo móvil y algoritmos de Aprendizaje Automático?

Capítulo 2

Fundamentos de la detección de anomalías

En este capítulo se aborda los conceptos necesarios que se necesita para comprender la detección de anomalías, así también se expondrá los diferentes proyectos e investigaciones enfocados en la detección de anomalías de conducción.

2.1. Detección de nomalías

Para comprender lo que implica la detección de anomalías, es necesario asimilar lo que és una anomalía y de que maneras estas pueden presentarse. Por lo tanto, se puede decir que las **anomalías**, o valores atípicos, son patrones en los datos que no se ajustan a una noción bien definida de un comportamiento normal.

Las anomalías pueden ser clasificadas dentro de una de las tres siguientes categorías:

1. **Anomalías de punto:** Las anomalías de punto son simplemente instancias únicas y anómalas dentro de un conjunto de datos más grande, es decir, éstas se encuentran separadas del resto de los datos. Por ejemplo, en la Figura 2.1, los puntos o_1 , o_2 y la región O_3 se encuentran fuera de los límites de las regiones normales (N_1 y N_2), y por lo tanto son anomalías puntuales debido a que son diferentes al conjunto de datos normales.

Este tipo de anomalía se considera la más simple y es el foco de la mayoría de las investigaciones enfocadas en la detección de valores atípicos.

2. **Anomalías contextuales (o condicionales):** Estos son puntos que sólo se consideran anómalos en un contexto específico. La noción de este contexto es inducida por la estructura en el conjunto de datos y debe especificarse como parte de la formulación del problema.

Este tipo de anomalías se han explorado con mayor frecuencia en los datos de series de tiempo y datos espaciales. La figura 2.2 muestra un ejemplo de serie temporal de la temperatura mensual de un área en los últimos 5 años, se debe tener en cuenta que la temperatura en el tiempo t_1 es la misma que en el tiempo t_2 , pero se produce en un contexto diferente, por lo tanto t_2 es considerada una anomalía.




FIGURA 2.1: Ejemplo de anomalías de punto en un conjunto de datos de 2 dimensiones.




FIGURA 2.2: Anomalía contextual t_2 en una serie temporal de temperatura.

3. **Anomalías colectivas:** Si una colección de instancias de datos relacionadas es anómala con respecto a todo el conjunto de datos, se denomina anomalía colectiva. Las instancias de datos individuales en una anomalía colectiva pueden no ser anomalías por sí mismas, pero su aparición conjunta como una colección es anómala.

La figura 2.3 ilustra un ejemplo que muestra una salida de electrocardiograma humano, se puede notar que la región resaltada en rojo denota una anomalía porque existe el mismo valor bajo durante un tiempo anormalmente prolongado (que corresponde a una Contracción prematura auricular). Se debe tener en cuenta que ese valor bajo por sí mismo no es considerada una anomalía.

En relación a lo expuesto previamente se puede definir como **detección de anomalías**, ó **valores atípicos**, a la identificación de puntos de datos, elementos, observaciones o eventos que no se ajustan al patrón esperado de un grupo determinado.

La detección de anomalías, se usa en distintos dominios de aplicaciones, por ejemplo: procesamiento de imágenes, detección de fraudes de tarjeta, sistemas de detección




FIGURA 2.3: Anomalía colectiva correspondiente a una contracción prematura auricular en un electrocardiograma humano.

de intrusión de red, etcetera.

2.2. Desafíos en la detección de anomalías

En un nivel abstracto, la detección de anomalías puede parecer una tarea simple. Sin embargo puede llegar a ser una tarea muy desafiante. A continuación se presenta algunos de estos desafíos.

- La definición de regiones normales es bastante difícil. En muchos casos, los límites entre las anomalías y los datos normales no son precisos. Por lo tanto, las observaciones normales podrían considerarse anomalías y viceversa.
- Lo que se considera normal hoy en día, puede no ser normal en el futuro.
- La mayor parte de las veces los enfoques para la detección de anomalías en un campo en específico no se pueden utilizar en otro campo.
- La poca disponibilidad de ejemplos positivos (anomalías) para el entrenamiento y validación del modelo de detección de anomalías.

2.2.1. Enfoques de detección de anomalías

Los enfoques que se pueden usar para este propósito se clasifican en las siguientes categorías:

Detección de anomalías supervisada

El uso de técnicas de aprendizaje supervisado requiere la disponibilidad de un conjunto de datos de entrenamiento etiquetados, tanto para clases normales como anómalas. El enfoque principal es construir un modelo predictivo para clases normales vs. anomalías, posteriormente tomar cualquier instancia de datos no visto, comparar con el modelo y determinar a que clase pertenece.

Existen dos principales inconvenientes que surgen con el uso de ésta técnica.

- La cantidad de instancias anómalas es muy inferior a la de las instancias normales, lo que genera un desequilibrio de distribución de clases durante el entrenamiento.
- La obtención de etiquetas precisas y representativas, en particular para la clase de anomalía, es un desafío.

Detección de anomalías semi-supervisada

Estas técnicas requieren un conjunto de entrenamiento con instancias etiquetadas, pero solo para la clase normal, esto hace que su uso sea más aplicable que las técnicas supervisadas, ya que no se requiere etiquetas para la clase anomalía.

El enfoque típico usado en éstas técnicas es construir un modelo para la clase correspondiente al comportamiento normal, y usar el modelo para identificar anomalías en los datos de prueba.

Detección de anomalías no supervisada

Las técnicas que operan de manera no supervisada no requieren datos de entrenamiento, razón por la cual son las más ampliamente utilizadas. Estas técnicas suponen que las instancias normales son mucho más frecuentes que las anomalías en los datos de prueba, en caso de que esta suposición no sea cierta, tales técnicas sufren de una alta tasa de falsas alarmas.

2.3. Trabajo relacionado

La identificación de comportamientos de conducción anormal es una parte indispensable para mejorar la seguridad de conducción, sin embargo, como se describió previamente, ésta no es una tarea sencilla. En los últimos años, se han propuesto varias técnicas para detectar conductas de manejo. Esta sección está dedicada al repaso de las mismas.

Dang-Nhac et al. [20], proponen un sistema combinado que se compone de dos módulos: uno para detectar el tipo de vehículo de los usuarios y el otro para detectar los eventos de conducción instantánea, independientemente de la orientación y la posición de los teléfonos inteligentes, éste sistema logra una precisión promedio del 98.33 % en la detección del tipo del vehículo (automóvil, motocicleta, bicicleta, entre otros) y una precisión promedio de 98.95 % en el reconocimiento de los eventos de conducción de los motociclistas al usar Random Forest como clasificador .

Por otra parte en [21] Ferreira et al. presentan una evaluación cuantitativa de 4 Algoritmos de Aprendizaje Automático (Bayesian Network BN, Artificial Neural Network ANN, Random Forest RF y Support Vector Machine SVM) con diferentes configuraciones, aplicadas en la detección de 7 tipos de eventos de conducción, entre eventos

normales y agresivos, utilizando datos recopilados de 4 sensores de teléfonos inteligentes Android (acelerómetro, aceleración lineal, magnetómetro y giroscopio); dando como resultado que el giroscopio y el acelerómetro son los mejores sensores para detectar eventos de conducción y que Random Forest (RF) es por lejos el Algoritmo de Aprendizaje Automático de mejor rendimiento, seguido de la forma más simple de ANN el Multi Layer Perceptron (MLP).

En [23] proponen el sistema MIROAD el cual muestra que el Dynamic Time Warping (DTW) es un algoritmo válido para detectar maniobras de conducción potencialmente agresivas, donde casi todos los eventos agresivos (97 %) se identificaron correctamente, utilizando el conjunto de sensores T (acelerómetro, giroscopio y el tono de voz). Así también en [24] se propone un sistema enfocado a desarrollar la conciencia del conductor mediante notificaciones en situaciones críticas que pueden desencadenar maniobras de manejo inseguras, mediante un modelo para detectar situaciones peligrosas basadas en Object-Oriented Bayesian Network (OOBN).

Así como los trabajos presentados previamente existe gran cantidad de trabajos ([25], [26], [27], [28], [29]) que usan los sensores de los teléfonos inteligentes (acelerómetro y giroscopio) para la detección de conducción agresiva, esto debido a que se tiene la ventaja de no comprar ni instalar ningún dispositivo y además de ser altamente portátil, sin embargo se depende bastante del rendimiento del receptor GPS y no es aplicable en áreas no disponibles para GPS.

Existen además otros enfoques para la detección de conducción agresiva de un conductor, por ejemplo en [22] proponen un método basado en Convolutional Neural Network (CNN) para detectar la emoción de conducción agresiva, mediante la utilización de imágenes faciales de un conductor obtenidas con una cámara de luz NIR y una cámara térmica.

2.4. Enfoque sobre el problema

Es evidente que éste tema fue ampliamente investigado y que tiene una gran variedad de propuestas de solución, sin embargo la mayoría de estas se basan en la detección mediante técnicas de aprendizaje supervisado, lo cual presenta la gran desventaja de requerir datos etiquetados para generar el modelo de detección; además gran parte de los trabajos relacionados proponen modelos generalizados para la detección y no así modelos específicos por usuarios, lo cual es crucial debido a que cada conductor presenta conductas individuales de manejo y manejan en condiciones distintas, es decir, la conducción de un usuario que circula por avenidas pavimentadas será distinta a la conducción de un usuario que circula por calles empedradas o la conducción de un usuario que circula por avenidas o calles concurridas será distinta a de los usuarios que circulen por calles relativamente descongestionadas.

Con la propuesta que se hace en este trabajo de grado se pretende brindar un prototipo de una herramienta que ayude a analizar las secuencias de los sensores de movimiento de un dispositivo móvil y permita detectar anomalías a partir de la información

obtenida de este análisis.

Para lograr este objetivo, se captura el conjunto de datos de los sensores de movimiento de un teléfono inteligente, mediante una aplicación móvil, posteriormente se divide y prepara los datos con técnicas de pre-procesamiento de datos. Una vez terminadas estas fases se entrena un modelo con el conjunto de entrenamiento y se valida con el conjunto de desarrollo. Finalmente se elige un modelo óptimo y una técnica para clasificar los valores atípicos, con el objetivo de cubrir un rango completo de los comportamientos normales y excluir con la mayor precisión posible las anomalías. Este método se puede apreciar mejor en la Figura 2.4.




FIGURA 2.4: Método de detección de anomalías propuesto.

2.5. Resumen del capítulo

De acuerdo a los conceptos presentados acerca de la detección de anomalías, los desafíos que presenta la detección de las mismas y los trabajos de investigación realizados en este campo hasta la fecha, se propone un método de detección de anomalías de conducción mediante el uso de técnicas de Aprendizaje Automático y el uso de un dispositivo móvil, los mismos serán tratados en profundidad en los siguientes capítulos.

Capítulo 3

Captura y preparación de datos

Contar con una gran cantidad de datos en cualquier problema de detección de anomalías es lo que permite generar modelos más precisos, debido a que nunca se sabe qué características pueden dar indicio de una anomalía, contar con múltiples tipos de datos es lo que permite ir más allá de una mera detección de anomalías puntuales y ser capaz de identificar anomalías contextuales o colectivas más sofisticadas. Sin embargo la obtención de estos datos no siempre es una tarea sencilla, por lo que muchas veces se debe encontrar una manera de generar los mismos.

En este capítulo se detallará el método de recolección de datos que se realizará para la presente investigación y las diferentes técnicas de análisis de datos que se aplicará.

3.1. Captura de datos

Actualmente existen varios enfoques para acceder a la información del conductor y del vehículo. En el primer enfoque, un conjunto de sensores y hardware adicional se implementan previamente en el vehículo, por ejemplo, cajas telemáticas (cajas negras provistas por compañías de seguros de automóviles), adaptadores de diagnóstico a bordo (OBD-II) enchufados en el controlador del vehículo red de área (CAN) ([30], [31]), la información registrada por estos dispositivos se puede recuperar o enviar a través de Internet. Sin embargo, esta estrategia requiere que los vehículos instalen dispositivos adicionales, lo que implica un mayor costo. Para superar estos inconvenientes, existe un enfoque alternativo el cual es usar teléfonos inteligentes para recopilar datos a través de un conjunto de sensores integrados, tales como sensores inerciales (acelerómetros y giroscopios), sistemas de posicionamiento global (GPS), magnetómetros, micrófonos, sensores de imagen (cámaras), sensores de luz, sensores de proximidad, sensores de dirección (brújula), entre otros.

Para el presente trabajo de grado se eligió el uso de teléfonos inteligentes para acceder a la información del tipo de conducción, por las razones que se presentaron anteriormente, con este enfoque se desarrolló una aplicación móvil basada en Android para recopilar datos de los sensores: acelerómetro y giroscopio, en intervalos de 1 segundo, los cuales en una primera instancia serán almacenados de manera interna en el dispositivo móvil. (Ver Figura 3.1)

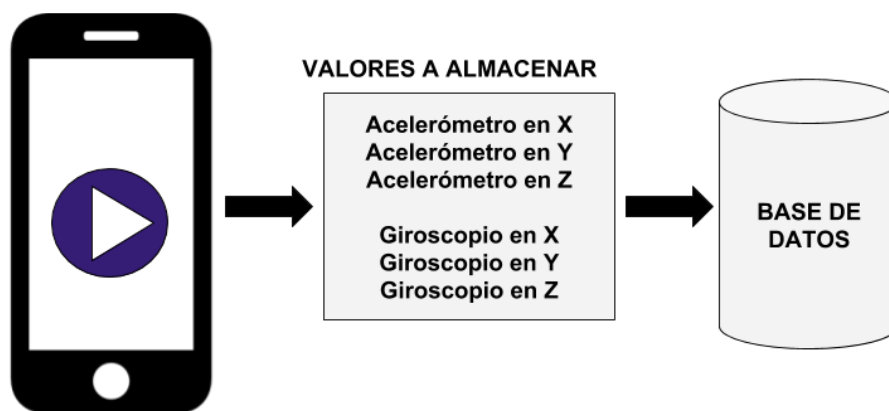


FIGURA 3.1: Recolección de datos, con intervalo de un segundo.

Para la captura de datos se usó un soporte para celular de parabrisas como se ve en la Figura 3.2; se realizó la captura en dos posiciones distintas (vertical y horizontal).



FIGURA 3.2: Soporte para celular de parabrisas, posición horizontal.

Cada captura, independientemente de la posición en la que se realizó, dió como resultado un conjunto de datos (dataset), donde por cada tiempo T (1 seg.) se tiene seis variables: acelerómetro en X (acc x), acelerómetro en Y (acc y), acelerómetro en Z (acc z), giroscopio en X (gyr x), giroscopio en Y (gyr y) y giroscopio en Z (gyr z). En la Figura 3.3 se aprecia un fragmento del conjunto de datos que se obtuvo en una captura.

3.2. Preparación de datos

El Aprendizaje Automático depende en gran medida de los datos. Son el aspecto más crucial que hace posible el entrenamiento de algoritmos y explica porque el aprendizaje automático se hizo tan popular en los últimos años. El principal problema es que

_id	acc_x	acc_y	acc_z	gyr_x	gyr_y	gyr_z
	Filter	Filter	Filter	Filter	Filter	Filter
1	-0.4353179...	9.60725402...	1.84175109...	9.15527343...	-0.0020294...	0.00770568...
2	-1.1603393...	9.73767089...	1.84773254...	-0.0500488...	0.02827453...	0.00379943...
3	-0.3013153...	9.57853698...	1.90994262...	0.00070190...	-0.0008697...	0.00354003...
4	-0.3479614...	9.59648132...	1.89201354...	0.00035095...	-0.0009918...	0.00372314...

FIGURA 3.3: Fragmento del conjunto de datos obtenido.

todos los conjuntos de datos tienen fallas, lo que hace a la preparación de datos un paso muy importante en el proceso de Aprendizaje Automático.

El propósito principal de la preparación de datos es manipular y transformar los datos en crudo, tal que, los datos puedan ser expuestos o hacerse accesibles más fácilmente [37], para lograr este propósito se debe seguir un proceso que implica la selección, el pre-procesamiento y la transformación de datos.

3.2.1. Selección de datos

La selección de datos implica los siguientes pasos:

- Seleccionar solo un subconjunto de los datos disponibles.
- Derivar o simular algunos datos a partir de los datos disponibles, en caso de ser necesario.
- Excluir aquellos datos que no son relevantes para el problema.

Para el presente trabajo se hará incapié sólo en el primer paso de esta fase, debido a que los datos con los que se cuenta son limitados ya que éstos fueron capturados para la investigación y como se indicó en la sección 3.1, esta captura se realizó, tanto de forma vertical como horizontal, a continuación se analizará las diferencias entre ellos.

En la Figura 3.4 se muestra fragmentos de las capturas obtenidas por el dispositivo móvil del manejo de un mismo usuario desde diferentes posiciones.

Si bien los valores capturados, son muy similares entre sí, los datos que fueron capturados con el dispositivo móvil en posición horizontal, presentan menos ruido, esto debido a que esta posición favorece la inercia del dispositivo cuando el vehículo está en movimiento, lo cual es una gran ventaja frente a los datos que fueron capturados de forma vertical, ya que estos fueron más susceptibles a sacudirse mientras el vehículo se desplazaba haciendo que los valores capturados en esta posición presenten valores de movimiento no sólo del vehículo sino también del dispositivo móvil, lo cual no es lo que se busca en el presente trabajo.




FIGURA 3.4: Gráfica de los sensores capturados en diferentes posiciones

Por las razones presentadas en el anterior párrafo se decidió trabajar con los datos capturados con el dispositivo móvil en posición horizontal, descartando así aquellos datos capturados en vertical.

3.3. Pre-procesamiento de datos

Una vez que se seleccionaron los datos con los que se trabajará, se debe proceder a pre-procesarlos, entrando así a la fase de Pre-procesamiento de datos, el objetivo de esta fase es reducir la cantidad de los datos, encontrar las relaciones entre ellos, normalizarlos, remover los valores atípicos y extraer las características de los datos. Esta fase incluye varias técnicas como la limpieza, integración, transformación y reducción de los datos [38].

3.3.1. Limpieza de datos

Los datos de las filas pueden tener registros incompletos, valores ruidosos, valores atípicos y datos inconsistentes. La limpieza de los datos en la mayoría de los casos es el primer paso del pre-procesamiento de datos. Esta técnica se usa para encontrar valores ausentes, suavizar el ruido en los datos, reconocer valores atípicos y corregir inconsistencias.

Manejo de valores ausentes

Los valores ausentes en el conjunto de datos pueden ser llenados usando cualquiera de las técnicas que se mencionan a continuación.

- **Ignorar / Eliminar:** En algunos casos es mejor ignorar o eliminar la tupla que contiene valores faltantes en lugar de llenar esta. Generalmente esta técnica se practica en conjuntos de datos que son muy grandes, donde el eliminar algunos datos no afectara la información que transmite nuestro conjunto de datos. Sin embargo cuando se trabaja con un conjunto de datos pequeño el eliminar las tuplas que contienen valores ausentes podría hacer perder información importante.

- **Llenar manualmente los valores ausentes:** Otra opción también es completar los valores faltantes si se comprende la naturaleza de los mismos, esto generalmente se realiza en conjunto de datos pequeños, ya que en los conjuntos grandes esta tarea requeriría bastante tiempo.
- **Llenar los valores ausentes con valores centrales (Media/Mediana):** Esta técnica es mucho mejor que las presentadas anteriormente. En esta técnica se inserta la media o la mediana del atributo respectivo a los valores faltantes.
- **Interpolación:** Es una forma confiable, precisa y científica de completar valores perdidos. Para usar esta técnica primero se debe desarrollar una relación entre los atributos y luego se predice el valor mas probable y preciso para los lugares faltantes, esto se puede lograr mediante regresión, formulación bayesiana e inducción por árboles de decisión.

Eliminar ruido (suavizado) de los datos

Para comprender esta técnica primero se debe definir qué es el ruido en los datos. El ruido en los datos es cualquier tipo de error aleatorio o variación en los atributos medidos; por otra parte los valores atípicos presentes en los datos también pueden considerarse como ruido.

Es importante destacar que el ruido presente en el conjunto de datos puede afectar en gran medida el resultado de nuestros algoritmos de Aprendizaje Automático, por lo tanto aquellos datos que contengan ruido no son considerados buenos datos y deben ser eliminados en lo posible. Sin embargo antes de eliminar estos, se debe ser capaz de detectarlos; para lograr este objetivo existen muchas técnicas que se pueden utilizar, una de estas técnicas es la **Visualización de datos**, la cual consiste en obtener una representación visual de nuestros datos, para poder evidenciar si existe ruido en los datos y/o valores atípicos.

En el presente proyecto se graficó histogramas de las frecuencias de cada característica de nuestro conjunto de datos y así visualizar de mejor manera si existe ruido o valores atípicos en el mismo. En la Figura 3.5 se puede evidenciar que los valores de cada sensor presentan asimetrías negativas y positivas, además de tener muchos valores bastante alejados de la media, lo que da un indicio de posibles valores atípicos.

En la Figura 3.6 se presenta una tabla con estadísticas descriptivas de nuestro conjunto de datos, esta tabla presenta: la cantidad de datos, su media, su desviación estándar, el valor mínimo y máximo del conjunto de datos y los percentiles 50, 25 y 75, cabe recalcar que el percentil 50 es el mismo que la mediana.

Con la información proporcionada en la Figura 3.6 ahora es más sencillo realizar un análisis del conjunto de datos, en primer lugar se evidencia que los valores obtenidos durante la captura, presentan desviaciones estándar muy pequeñas entre 0.02 y 0.79 y sin embargo la diferencia entre los valores mínimo y máximo son realmente grandes, por ejemplo para el Acelerómetro en X, la diferencia es 16 aproximadamente (Valor mínimo: -1.998 y valor máximo: 14.31), esto quiere decir que nuestro conjunto de datos




FIGURA 3.5: Histograma de frecuencias del conjunto de datos

	acc_x	acc_y	acc_z	gyr_x	gyr_y	gyr_z
count	20000.000000	20000.000000	20000.000000	20000.000000	20000.000000	20000.000000
mean	9.744480	0.263008	-0.992000	0.000492	-0.000743	0.000096
std	0.449664	0.582752	0.786257	0.048442	0.023572	0.039129
min	-1.998215	-4.037933	-8.923569	-0.790817	-1.261871	-1.051468
25%	9.677216	-0.018173	-1.399807	-0.006760	-0.005203	-0.007908
50%	9.766968	0.215057	-1.005829	0.000000	-0.000046	-0.000015
75%	9.822723	0.555355	-0.725754	0.006653	0.003510	0.008057
max	14.312866	7.334473	12.555618	0.621399	0.599594	1.495499

FIGURA 3.6: Tabla de resultados estadísticos del conjunto de datos.

presenta mucho ruido, considerando como ruido o valores atípicos, aquellos valores muy alejados de la media.

Para eliminar el ruido que presenta nuestro conjunto de datos se aplicó la **Regla 68-95-99.7**, conocida también como la **Regla empírica**, donde suponiendo que el conjunto de datos con el que se trabaja tiene una distribución normal, la desviación estándar se puede usar para determinar la proporción de valores que se encuentran dentro de un

rango particular del valor medio. Para tales distribuciones, siempre ocurre que el 68 % de los valores están a menos de una desviación estándar (1SD) del valor medio, que el 95 % de los valores están a menos de dos desviaciones estándar (2SD) de la media y que el 99 % de valores están a menos de tres desviaciones estándar (3SD) de la media. En la Figura 3.7 se muestra este concepto de forma esquemática.




FIGURA 3.7: Regla 68-95-99.7

En la Figura 3.8, se puede observar como se comporta la regla 68-95-99.7 sobre los valores del sensor del acelerómetro en Y, por lo que para eliminar el ruido en nuestro conjunto de datos se tiene dos opciones, eliminar los valores después de tres desviaciones estándar de la media, en caso de considerar que nuestro conjunto de datos presenta pocas anomalías o valores atípicos, o eliminar los valores después de dos desviaciones estándar en caso de estar seguro que nuestro conjunto de datos presenta una gran cantidad de ruido en los datos, en nuestro caso la mayoría de nuestros datos pertenecen a comportamientos normales de conducción por lo que sólo eliminaremos los valores que se encuentran después de tres desviaciones estándar de la media.

Fusión o integración de datos

Cuando se trabaja con datos del mundo real, es posible que los datos que se requiere no se encuentren en un mismo conjunto de datos, en éstos casos, se necesita recopilar datos de diferentes fuentes y fusionarlos en un solo conjunto de datos; este proceso recibe el nombre de Fusión o Integración de datos. Uno de los problemas más comunes de este proceso es la redundancia.

Este proceso no se aplicó en la investigación debido a que sólo se capturo los datos por medio del dispositivo móvil, por lo cual no se tiene el problema de tener más de una fuente de datos.




FIGURA 3.8: Regla 68-95-99.7 aplicada a los valores de los sensores del acelerómetro en Y.

Transformación de datos

La transformación de los datos es el proceso donde se cambia la naturaleza de los datos, dicho proceso usa algunas estrategias para poder extraer información importante del conjunto de datos; algunas de las estrategias para la transformación de datos son:

- **Agregación:** En esta técnica, la operación de resumen o agregación se aplica sobre los datos. Por ejemplo: los datos de ventas diarias se pueden usar para calcular el monto mensual y anual en ventas, para posteriormente agregar estos datos calculados al conjunto de datos.
- **Discretización:** Con esta técnica se construye y reemplaza valores en bruto de un atributo numérico por valores de intervalo.
- **Construcción de atributos / Ingeniería de características:** Esta técnica es útil para generar información adicional a partir de datos vagos, además puede ser adecuada cuando se tiene menos características pero aún contienen información oculta para extraer.
- **Normalización / Estandarización:** La normalización o estandarización se define como el proceso de reescalar datos originales sin cambiar su comportamiento o naturaleza. Se define un nuevo límite (generalmente entre 0 y 1) y se convierte los datos en consecuencia. Esta técnica es útil en algoritmos de clasificación que involucran redes neuronales o algoritmos basados en la distancia (por ejemplo, KNN, K-means). Algunas técnicas de normalización son:

- *Normalización Min-Max*: En este método, cada entrada se normaliza entre unos límites definidos:

$$x_{normalizado} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (3.1)$$

Presenta el problema de que comprime los datos de entrada entre unos límites fijos, que por lo general son 0 y 1. Esto quiere decir que si existe ruido, éste va a ser ampliado, lo que hace que este método no sea adecuado para señales estables.

- *Escalado estándar (Standard Scaler)*: Es un método alternativo al escalado de variables, consiste en restar a cada dato la media de la variable y dividirlo por la desviación típica.

$$x_{normalizado} = \frac{x - x_{media}}{x_{desvSt}} \quad (3.2)$$

Este método es adecuado para normalizar señales estables, no obstante, tanto la media como la desviación estándar son muy sensibles a valores anómalos. Una alternativa de solución de esto es la eliminación de anomalías antes de realizar la normalización.

- *Escalado sobre el valor máximo*: Este método, presenta la idea de escalar los datos dividiendo éstos entre su máximo valor.
- *Escalado robusto (Robust scaler)*: El escalado robusto consiste en eliminar la mediana y escala los datos de acuerdo con el rango de intercuartil (IQR). Este método es robusto para valores atípicos.

Reducción de datos

Este proceso se basa en la adopción de algunas estrategias, tal que el análisis de datos reducidos produce la misma información producida por los datos originales. Algunas de las estrategias incluyen: análisis de componentes principales (PCA), selección de un subconjunto de atributos, agrupación y muestreo entre otros.

Análisis de componentes principales (PCA)

El Análisis de Componentes Principales (PCA - Principal Component Analysis) es una técnica que se usa ampliamente para aplicaciones como reducción de dimensionalidad, compresión de datos con pérdida, extracción de características y visualización de datos [39].

PCA es una técnica estadística no supervisada y no paramétrica, que se utiliza para la reducción de dimensionalidad. Esta técnica es un paso importante debido a que la alta dimensionalidad en el campo de aprendizaje automático puede llevar al sobreajuste del modelo, reduciendo así su capacidad de generalización, Richard Bellman en [40] describe este fenómeno como la "Maldición de la Dimensionalidad". Además, el uso de esta técnica puede mejorar directamente el rendimiento de los modelos de Aprendizaje Automático.

PCA combina las variables de entrada de una manera específica, luego se deshace de las variables "menos importantes" al mismo tiempo conserva las partes más valiosas (o componentes principales¹) de todas las variables.

Cuando se usa PCA enfocado al aprendizaje automático se siguen los siguientes pasos:

1. Dividir el conjunto de datos d -dimensional en conjunto de entrenamiento, desarrollo y prueba.
2. Estandarizar / Normalizar el conjunto de datos según el conjunto de entrenamiento.
3. Construir la matriz de covarianza.
4. Descomponer la matriz de covarianza en sus vectores y valores propios.
5. Ordenar los valores propios disminuyendo el orden para clasificar los vectores propios correspondientes.
6. Seleccionar k vectores propios que corresponden a los k valores propios más grandes, donde k es la dimensionalidad del nuevo subespacio de entidad ($k \leq d$).
7. Construir una matriz de proyección \mathbf{W} a partir de los "top" k vectores propios.
8. Transformar el conjunto de entrenamiento de entrada d -dimensional \mathbf{X} utilizando la matriz de proyección \mathbf{W} para obtener el nuevo subespacio de característica k -dimensional.

Dividir el conjunto de datos

Dado que se cuenta con un conjunto de datos para generar el modelo de Aprendizaje Automático, este se divide en tres partes: conjunto de entrenamiento², desarrollo³ y prueba⁴, sin embargo esto no es una tarea trivial; ya que si no se hace correctamente el resultado puede ser desastroso.

En [41] se dice que la división del conjunto de datos tiene un gran impacto en la productividad, por lo cual es importante que al elegir todos nuestros subconjuntos estos deben tener la **misma distribución** y deben ser elegidos aleatoriamente del conjunto de datos.

¹**Componente principal**, es una combinación lineal normalizada de las características originales en el conjunto de datos.

²**Conjunto de entrenamiento**, es la muestra de datos utilizada para ajustar el modelo de Aprendizaje Automático.

³**Conjunto de desarrollo**, es la muestra de datos utilizada para proporcionar una evaluación imparcial de un modelo ajustado con el conjunto de entrenamiento mientras se ajustan los hiperparámetros del modelo.

⁴**Conjunto de prueba**, es la muestra de datos utilizada para proporcionar una evaluación imparcial de un ajuste final del modelo en el conjunto de entrenamiento.




FIGURA 3.9: División del conjunto de entrenamiento.

Conjunto de entrenamiento	70 %	21000
Conjunto de desarrollo	15 %	4500
Conjunto de prueba	15 %	4500
Conjunto de datos	100 %	30000

CUADRO 3.1: Tabla de división del conjunto de datos.

Por otra parte el tamaño del conjunto de desarrollo y prueba deben ser lo suficientemente grandes como para que los resultados del desarrollo y prueba sean representativos para el rendimiento del modelo. Para conjuntos de datos grandes (mayores a un millón), el conjunto de desarrollo y prueba puede tener alrededor de 10000 ejemplos cada uno, es decir, el 1 % del total de datos.

Otras consideraciones que deben tomarse en cuenta en la práctica son:

- La división del conjunto de entrenamiento/desarrollo/prueba siempre debe ser la misma para todos los experimentos, por lo tanto se debe contar con script reproducible para crear la división entrenamiento/desarrollo/prueba.
- Se debe probar que los conjuntos de desarrollo y prueba provengan de la misma distribución.

En la presente investigación nuestro conjunto de datos cuenta con 30000 ejemplos, por lo que la división de nuestro conjunto de datos será la que se observa en el Cuadro 3.1.

Estandarizar / Normalizar el conjunto de datos

En la sección 3.3.1 ya se describió lo que es la estandarización o normalización de datos y algunos de los tipos de escalado que existen; por lo tanto esta sección sólo se limitará a la elaboración de un análisis para decidir que técnica de escalado es la más adecuada para el conjunto de datos, en la Figura 3.10 se puede apreciar una fracción del conjunto de datos capturado, la cual es la base con la que se realizará el análisis comparativo con los distintos tipos de escalado.




FIGURA 3.10: Visualización de los parámetros de conducción capturados.

Para probar los diferentes tipos de escalado, se los ajusto con los datos que ya no presentan ruido o valores atípicos del conjunto de entrenamiento.

El primer tipo de escalado que se realizó sobre el conjunto de datos capturados fue la **Normalización Min-Max**, el cual se realizó entre los límites 0 y 1, los resultados obtenidos se muestran en la figura 3.11a, donde se puede apreciar que los valores del acelerómetro, en sus tres ejes, no se ven deformados después de haber sido escalados con ésta técnica y los valores del giroscopio, los cuales son más estables se tornan deformados, considerando como datos estables aquellos datos que se presentan como una línea en cero con pocas fluctuaciones; esta deformación puede ser ventajosa al hacer más visible pequeñas curvas que anteriormente eran imperceptibles, sin embargo conlleva el peligro de que pueda ampliar ruido existente en nuestros datos que no pudimos eliminar en el paso previo a esta tarea.

La segunda técnica de normalización que se aplicó sobre los datos fue el **escalado estándar**, el resultado se puede apreciar en la figura 3.11b, observando detalladamente los resultados se puede evidenciar que son muy similares a los obtenidos con la normalización Min-Max, las únicas diferencias que se pueden evidenciar son que el nuevo rango de los datos es más amplio con media en cero y valores que oscilan principalmente entre 2 y 2, y que se amplía un poco más algunas de las fluctuaciones que presentan los giroscopios.

Para la tercera normalización de datos se aplicó la técnica de **escalado sobre el valor máximo**, los resultados se presentan totalmente diferentes a los que se obtuvo anteriormente, sin embargo se observa claramente que los valores del acelerómetro no presentan mucho cambio con la diferencia de que la media de estos valores son distintas para cada uno, y los valores de los giroscopios se comportan como en los anteriores, como se puede ver en la figura 3.11c. Esta técnica presenta los peores resultados, ya que no deja nuestro conjunto de datos en un mismo rango lo cual complica su trabajo.

La última técnica aplicada es el **escalado robusto**, su resultado puede ser observado

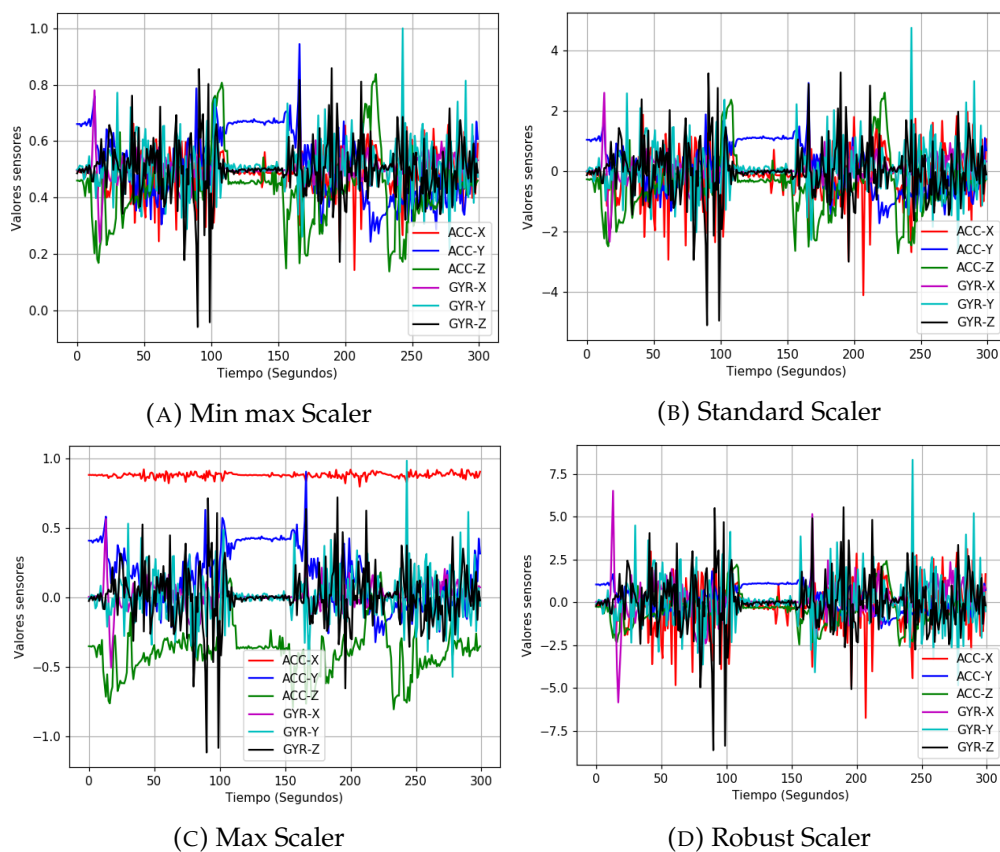


FIGURA 3.11: Gráfica resultante de aplicar diferentes tipos de normalizaciones a un conjunto de datos.

en la figura 3.11d, el cual puede ser considerado bastante similar a las dos primeras técnicas, con diferencia de que este escalado pronuncia mucho más las fluctuaciones de los valores de los giroscopios.

Para decidir el mejor método de normalización que se puede aplicar a los datos capturados, primero se descartará completamente el **método de escalado sobre el valor máximo** debido a que los resultados que presentó fueron totalmente desalentadores ya que los valores después del escalado no compartían los mismos límites, por otra parte los restantes tres tipos de escalado son muy similares, lo cual complica la elección de escalado correcto, sin embargo cuando se usa PCA se debe ser muy cuidadoso, debido a que si se tiene una variable con una desviación estándar alta, esta tendrá un mayor peso en el cálculo del eje que una variable con una desviación estándar baja, por lo cual este puede ser un parámetro de decisión importante para elegir el tipo de escalado más adecuado.

En la tabla 3.2 se muestra la media y la desviación estándar de cada variable después de haber aplicado los diferentes tipos de escalado sobre los datos. Como se puede evidenciar en los escalados sobre el valor máximo y estándar, las desviaciones estándar son muy diferentes, en cuanto al escalado Min-Max las desviaciones estándar de cada variable son casi las mismas todas oscilan entre 0.166759 y 0.169528, lo cual se adecúa muy bien para el análisis de componentes principales, que es lo que se busca en este punto.

		ACC X	ACC Y	ACC Z	GYR X	GYR Y	GYR Z
Min-Max	Media	0.494631	0.504011	0.500105	0.497873	0.499490	0.499922
	Desv. Est.	0.169528	0.168058	0.166759	0.167592	0.167005	0.166876
	Mínimo	-3.932480	-0.736326	-1.182118	-2.239772	-8.435568	-3.984707
	Máximo	2.216958	2.543331	3.373446	2.645991	4.752865	6.877400
Estándar	Media	-0.053019	0.006007	0.035521	0.013953	-0.007687	-0.001008
	Desv. Est.	1.956964	1.116028	1.270322	1.537762	1.591346	1.525546
	Mínimo	-51.157948	-8.230720	-12.779184	-25.105641	-85.147607	-40.998624
	Máximo	19.828881	13.548560	21.923844	19.724263	40.521651	58.300659
Valor Máximo	Media	0.879073	0.132640	-0.296123	0.003375	-0.010434	0.000820
	Desv. Est.	0.040565	0.293892	0.234706	0.332638	0.330862	0.333426
	Mínimo	-0.180264	-2.036399	-2.663783	-5.430323	-17.712144	-8.959693
	Máximo	1.291199	3.698900	3.747990	4.266974	8.416149	12.743336
Robusto	Media	-0.159037	0.083165	0.027062	0.039046	-0.083081	0.007354
	Desv. Est.	3.178981	1.031395	1.181458	3.848120	2.807440	2.582457
	Mínimo	-83.176214	-7.528934	-11.891205	-62.820606	-150.286234	-69.393756
	Máximo	32.138026	12.598724	20.384211	49.362424	71.418446	98.700906

CUADRO 3.2: Tabla con estadísticas descriptivas de los datos escalados con diferentes técnicas.

Aplicar PCA al conjunto de datos

Aunque al inicio de esta subsubsección se explica en detalle algunos de los pasos del funcionamiento interno de PCA, existe una clase llamada PCA implementada en SCIKIT-LEARN, la cual automatiza todos los pasos siguientes; sin embargo se debe decidir la cantidad correcta de componentes principales para nuestro conjunto de datos, para ello haciendo uso de esta clase se calcula la varianza de cada atributo y posteriormente se grafica los resultados (Ver Figura 3.12).




FIGURA 3.12: Gráfico de la varianza vs el número de componentes.

El Gráfico 3.12 indica que seleccionando 4 componentes se puede preservar alrededor del 95 % de la varianza total de los datos y que seleccionando 3 componentes se conserva alrededor del 80 % de la varianza de los datos, usar cualquiera de esas cantidades de componentes tiene sentido, ya que no se usará el 100 % de la varianza, porque denota todos los componentes y sólo se desea usar los principales.

3.4. Resumen del capítulo

En este capítulo se ha descrito la forma en la que se realizó la captura del conjunto de datos de conducción y la preparación del conjunto de datos, mediante distintas técnicas como la selección, limpieza, reducción y transformación de datos; con el fin de que estos valores sean una mejor entrada para el algoritmo de aprendizaje automático que se aplicará en el siguiente capítulo.

Capítulo 4

Aprendizaje Automático para la detección de anomalías

El término Aprendizaje Automático se refiere a la detección automática de patrones significativos dentro de un conjunto de datos [32]. En las últimas décadas se ha convertido en una herramienta común en casi cualquier tarea que requiera la extracción de información de gran cantidad de datos, por lo cual se ha convertido en una de las áreas de más rápido crecimiento de la informática.

Si bien el Aprendizaje Automático puede resolver algunos problemas que son resueltos con algoritmos tradicionales, ha superado a éstos en problemas tales como el reconocimiento de imágenes, voz, lenguaje, escritura, juegos, robótica, análisis de datos, análisis de series de tiempo, etc. Desde esta perspectiva, se espera que mediante la aplicación del Aprendizaje Automático se pueda generar un modelo que se ajuste a un comportamiento normal esperado para un usuario.

4.1. Aprendizaje Supervisado, Aprendizaje no Supervisado y Aprendizaje Semi-supervisado

Existen diversas formas de clasificar los paradigmas de aprendizaje que existen, sin embargo en el presente trabajo sólo se tratarán el supervisado, el no supervisado y el semi-supervisado.

4.1.1. Aprendizaje Supervisado

El **Aprendizaje Supervisado** es aquel que cuenta con variables de entrada (X) y una variable de salida (Y), este tipo de aprendizaje utiliza un algoritmo para aprender la función de mapeo desde la entrada hasta la salida.

$$Y = f(X) \quad (4.1)$$

El objetivo de este tipo de aprendizaje es aproximar la función de mapeo de tal forma que cuando tenga datos de entrada nuevos (X) pueda predecir las variables de salida (Y) para esos datos.

Este tipo de aprendizaje aborda dos tipos de problemas: clasificación y regresión. Los problemas de **Clasificación** son aquellos donde la variable de salida es una categoría,

como por ejemplo: "Rojo", "Azul", o "Sano", "Enfermo", por otra parte en los problemas de **Regresión** la variable de salida es un valor real, tal como: "precio" o "altura". Algunos de los tipos de problemas más comunes construidos sobre la clasificación y la regresión incluyen la recomendación y la predicción de series temporales.

4.1.2. Aprendizaje no Supervisado

Por otro lado el **Aprendizaje no Supervisado** es aquel donde sólo se cuenta con datos de entrada (X) y no hay variables de salida correspondientes, su objetivo principal consiste en modelar la estructura o distribución subyacente en los datos para aprender más acerca de los mismos.

En cuanto a los problemas del Aprendizaje sin supervisión, pueden ser agrupados en dos: agrupamiento y asociación. El **Agrupamiento** es aquel donde se desea descubrir las agrupaciones inherentes en el conjunto de datos, como por ejemplo agrupar clientes por comportamiento de compra. Por otra parte la **Asociación** es aquella que desea descubrir reglas que describen grandes porciones de sus datos, por ejemplo las personas que compran X también tienden a comprar Y. Algunos de los algoritmos de aprendizaje sin supervisión más populares son: K-means (para problemas de agrupamiento) y algoritmo Apriori (para problemas de aprendizaje de reglas de asociación).

4.1.3. Aprendizaje Semi-Supervisado

Por último se encuentra el **Aprendizaje Semi-supervisado**, el cual abarca aquellos problemas donde se tiene gran cantidad de datos de entrada (X) y sólo algunos de los datos están etiquetados (Y). Este tipo de problemas se encuentran entre el aprendizaje supervisado y el no supervisado, además es importante señalar que muchos de los problemas de Aprendizaje Automático en el mundo real se encuentran en esta área, esto debido a que resulta costoso o puede requerir mucho tiempo etiquetar el conjunto de datos, mientras que los datos no etiquetados son baratos, además de ser fáciles de recolectar y almacenar. Este tipo de problemas pueden usar una combinación de técnicas supervisadas y no supervisadas para ser resueltos.

Dado que los métodos de Aprendizaje Supervisado requieren una gran cantidad de datos de entrenamiento etiquetados, es importante aclarar que la recolección de muestras negativas (conducción anómala) es difícil y riesgosa para este estudio en particular; además el enfoque supervisado presenta una limitación potencial, la cual es: la detección de nuevos patrones atípicos, esto debido a que el modelo resultante sólo está entrenado para reconocer un conjunto limitado de patrones anómalos, por lo cual al momento en que se presente un nuevo patrón este modelo será incapaz de reconocerlo.


Por otra parte el enfoque sin supervisión tiene la ventaja de no requerir información etiquetada, sin embargo a menudo sufre altas tasas de falsas alarmas y bajas tasas de detección [33].

En muchas aplicaciones, incluyendo la del presente trabajo de grado, los ejemplos normales son fáciles de conseguir, mientras que los anómalos son bastante difíciles de

obtener, en consecuencia, para la realización de este estudio, se ha optado por la aplicación del enfoque Semi-supervisado. De esta manera, como se mencionó en el Capítulo 2, el enfoque de **detección de anomalías Semi-supervisado** sólo dispone de muestras normales en el conjunto de entrenamiento; es decir, no se puede obtener información sobre anomalías, por lo tanto las muestras desconocidas se clasifican como valores atípicos, siempre y cuando su comportamiento sea muy diferente al de las muestras normales ya conocidas. Por lo tanto en este trabajo, se propone un método de detección de anomalías de conducción semi-supervisado que consta de dos componentes: un modelo ajustado al comportamiento normal de manejo de un usuario y un método de umbral para detección de valores atípicos.

Para la generación del modelo de detección de anomalías se optó por algoritmos de aprendizaje automático enfocados en series de tiempo, dado que los datos, de los sensores capturados por el dispositivo móvil, dependen del tiempo en el que fueron capturados; por lo cual el primer paso a realizar es la generación de pequeñas fracciones de series temporales. En el Cuadro 4.1 se muestran los resultados de diferentes tamaños de series de tiempo.

Según lo observado en el Cuadro 4.1 se descarta la serie de tiempo que cuenta con sólo un paso en el tiempo debido a que su uso se limitaría a una mera detección de anomalías puntuales, lo cual no es el objetivo del presente trabajo de grado, por otra parte la serie temporal que tiene dos pasos no es lo suficientemente descriptiva razón por la que esta serie de tiempo también queda descartada, llegando a este punto momentáneamente no es posible definir la cantidad correcta de pasos en las series de tiempo, por lo cual al igual que la cantidad de componentes principales, será un parámetro a optimizar en los diferentes experimentos que se realizará en las siguientes secciones. Cabe recalcar que el dominio de esta variable estará entre 3 a 5 pasos y el de la cantidad de componentes principales estará entre 3 y 4.



CUADRO 4.1: Tabla con diferentes tamaños de series de tiempo para 3 y 4 componentes principales.

Una vez definido como se tratará el conjunto de datos se puede proceder con la siguiente fase (modelo ajustado al comportamiento normal).

4.2. Modelo del comportamiento normal

Este modelo es una de las partes más importantes debido

4.3. Aprendizaje automático para análisis de series de tiempo

Para entender la importancia de las series de tiempo se puede tomar la siguiente analogía, los seres humanos no comienzan a pensar desde cero cada segundo, por lo que al leer un documento se comprende cada palabra basándose en la comprensión de las palabras anteriores, es decir, no se elimina todo y se empieza a pensar de cero cada vez, dada ésta afirmación se puede decir que los pensamientos de los seres humanos tienen persistencia.

Las redes neuronales tradicionales no tienen persistencia de los datos, lo que para algunos problemas en concreto, incluyendo el que se aborda en este trabajo, es una gran deficiencia. Con el fin de resolver este tipo de problemas aparecen las Redes Neuronales Recurrentes (RNN), las cuales son un tipo de red neuronal artificial propuesta en los años 80 ([34], [35], [36]) diseñada para reconocer patrones en secuencias de datos, como texto, genomas, escritura a mano, datos de series de tiempo numéricos que emanan de sensores, entre otros.

La estructura de las RNN es similar a la de un perceptrón multicapa estándar, con la diferencia de que permite conexiones entre unidades ocultas asociadas con un retardo de tiempo; a través de estas conexiones, el modelo puede retener información sobre el pasado, lo que le permite descubrir correlaciones temporales entre eventos que están muy lejos unos de otros en los datos.

Las RNN tienen una cierta memoria de lo que sucedió anteriormente en una secuencia de datos, esto ayuda al sistema a ganar contexto de los datos. Teóricamente se dice que las RNN tienen memoria infinita, es decir, este tipo de redes tienen la capacidad de mirar hacia atrás indefinidamente; sin embargo en la práctica solo se puede mirar atrás unos últimos pasos.

LSTM está diseñado para obtener un flujo constante de errores en el tiempo y proteger este flujo de errores

Bibliografía

- [1] DANG-NHAC, L., DUC-NHAN, N., THI-HAU, N., y HA-NAM, N. Vehicle mode and driving activity detection based on analyzing sensor data of smartphones, *Sensors* v. 18, 4 (2018), 1036.
- [2] FERREIRA, J., CARVALHO, E., FERREIRA, B., DE SOUZA, C., SUHARA, Y., PENTLAND, A., y PESSIN, G. Driver behavior profiling: An investigation with different smartphone sensors and machine learning, *PLoS One* v. 12, 4 (2017), e0174959.
- [3] WHO-LEE, K., SIK-YOON, H., MIN-SONG, J., y RYOUNG-PARK, K. Convolutional Neural Network-Based Classification of Driver's Emotion during Aggressive and Smooth Driving Using Multi-Modal Camera Sensors, *Sensors* v. 18, 4 (2018), 957.
- [4] JOHNSON, D., y TRIVEDI, M. Driving Style Recognition Using a Smartphone as a Sensor Platform. En: Intelligent Transportation Systems (ITSC), 2011 14th International IEEE Conference, 2011. p. 1609–1615.
- [5] KRIDALUKMANA, R., YAN-LU, H., y NADERPOUR, M. An Object Oriented Bayesian Network Approach for Unsafe Driving Maneuvers Prevention System, 2017 12th International IEEE Conference.
- [6] BHOYAR, V., LATA, P., KATKAR, J., PATIL, A., y JAVALE, D. Symbian Based Rash Driving Detection System. *Int. J. Emerg. Trends Technol. Comput. Sci.* 2013;2:124–126.
- [7] CHEN, Z., YU, J., ZHU, Y., CHEN, Y., y LI, M. D3: Abnormal Driving Behaviors Detection and Identification Using Smartphone Sensors; Proceedings of the 12th Annual IEEE International Conference on Sensing, Communication, and Networking; Seattle, WA, USA. 22–25 de Junio 2015; pp. 524–532.
- [8] EREN, H., MAKINIST, S., AKIN, E., y YILMAZ, A. Estimating Driving Behavior by a Smartphone; Proceedings of the Intelligent Vehicles Symposium; Alcalá de Henares, España. 3–7 de Junio 2012; pp. 234–239.
- [9] BOONMEE, S., y TANGAMCHIT, P. Portable Reckless Driving Detection System; Proceedings of the 6th IEEE International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology; Pattaya, Chonburi, Tailandia. 6–9 de Mayo 2009; pp. 412–415.
- [10] KOH, D.-W., y KANG, H.-B. Smartphone-Based Modeling and Detection of Aggressiveness Reactions in Senior Drivers; Proceedings of the IEEE Intelligent Vehicles Symposium; Seoul, Korea. 28 de Junio – 1 de Julio 2015; pp. 12–17.

- [11] ZALDIVAR, J., CALAFATE, C.T., CANO, J.C., y MANZONI, P. Providing accident detection in vehicular networks through OBD-II devices and Android-based smartphones; Proceedings of the 2011 IEEE 36th Conference on Local Computer Networks; Bonn, Alemania. 4–7 de Octubre 2011; pp. 813–819.
- [12] ARAUJO, R., IGREJA, A., DE CASTRO R., y ARAUJO, R. Driving coach: A smartphone application to evaluate driving efficient patterns; Proceedings of the 2012 IEEE Intelligent Vehicles Symposium (IV); Alcala de Henares, España. 3–7 de Junio 2012; pp. 1005–1010.
- [13] SHAI, S., y SHAI, B. Understanding Machine Learning: From Theory to Algorithms (2014).
- [14] XUE, Z., SHANG, Y., y FENG, A. Semi-supervised outlier detection based on fuzzy rough C-means clustering. *Mathematics and Computers in Simulation*, vol. 80, no. 9, pp. 1911–1921.
- [15] RUMELHART, D. E., HINTON, G. E., y WILLIAMS, R. J. (1986). Learning representations by backpropagating errors. *Nature*, 323(6088), 533–536.
- [16] ELMAN, J. Finding structure in time. *Cognitive Science* (1990), 14(2), 179–211.
- [17] WERBOS, P. J. Generalization of backpropagation with application to a recurrent gas market model. *Neural Networks* (1988), 1(4), pp. 339–356.
- [18] PYLE, D. Data preparation for data mining (1999), pp. 90.
- [19] SUAD, A., WESAM, S. Review of Data Preprocessing Techniques in Data Mining. *Journal of Engineering and Applied Sciences* 12(16): 4102–4107. 2017.
- [20] BISHOP, M. C. Pattern recognition and Machine Learning (2006), pp. 561.
- [21] BELLMAN, R. E. Dynamic programming (2003). Courier Dover Publications. ISBN 978-0-486-42809-3.
- [22] MOINDROT, O. y GENTHIAL, G. Splitting into train, dev and test sets. 24 de Enero en 2018. Disponible en: <https://cs230-stanford.github.io/train-dev-test-split.html>.